

회귀분석 기말고사 대비 백지 테스트 자료

Final Exam Scope & Tips (Audio Analysis)

- **일정:** 다음 주 월요일
- **범위:** Lecture Note 9 ~ 16 (제외: 13장 전체, 16장 심화)
- **Chapter 9 (Hypothesis):** F-test, General Linear Hypothesis 중요.
- **Chapter 10 (Diagnostics):** Influence measures (Cook's D, DFFITS, DFBETAS), Studentized Residuals. (제외: Residual Plot, Multiple Comparison).
- **Chapter 11 (Leverage):** Leverage 개념 및 성질 중요.
- **Chapter 12 (Qualitative):** 계산 문제 출제 가능성 높음. Interactions, Dummy Variables 꼼꼼히 볼 것.
- **Chapter 13 (WLS):** 시험 범위 제외.
- **Chapter 14 (Correlated Errors):** 시계열 관련 중요. AR(1), Durbin-Watson 등 포함.
- **Chapter 15 (Model Selection):** Criteria, Selection Procedures 중요.
- **Chapter 16 (Penalized):** Collinearity, Bias-Variance, Ridge/Lasso 기본 개념(Concept)만. (제외: PCR, SVD, Elastic Net 알고리즘 등 심화 내용).

9. Multiple regression 3

다중 회귀 추론 (Inference for Multiple Regression)

1개 이상 변수를 Dropping 하는 과정

- 귀무가설과 대립가설

$H_0 : \beta_6 = \beta_7 = 0$ $H_1 : \beta_6, \beta_7$ 중 적어도 하나는 0이 아님? $df_R = n - (p - 1)$ (제약 조건 $\beta_a + \beta_b = C$ 로 계수가 1개 줄어듦)

- 검정 방법: 두 모형간 비교

- 축소 모형 (Reduced Model) :
 $Reduced(H_0) : Y_i = \beta_0 + \sum_{j=1}^5 \beta_j X_{ij} + \epsilon_i$
- 완전 모형 (Full Model) :
 $Full(H_1) : Y_i = \beta_0 + \sum_{j=1}^7 \beta_j X_{ij} + \epsilon_i$
 - $(F\text{-값}) \geq F_{\alpha}(2, n - p - 1)$ 일때 H_0 를 기각

F-test 유형별 가설 설정 및 모형 비교

F-test type I (모형의 유의성 검정)

- 가설:** $H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$ $H_1 : \exists \beta_k \neq 0$
 $k \in \{i_1, \dots, i_j\} \subset \{0, 1, \dots, p\}$

F-test type II (두 계수의 동일성 검정)

- 가설: $H_0 : \beta_a = \beta_b$ (β^*) $H_1 : \beta_a \neq \beta_b$
- 모형 재정의 (Full Model)**
 - Full model : $Y_i = \beta_0 + \dots + \beta_a x_{ia} + \dots + \beta_b x_{ib} + \dots + \beta_p x_{ip} + \epsilon_i$ $df_F = n - p - 1$
- 모형 재정의 (Reduced Model)**
 - $H_0 : \beta_a = \beta_b = \beta^*$ 로 치환 ($\beta_b = \beta^*$)
 - Reduced model : $Y_i = \beta_0 + \dots + \beta^* x_{ia} + \dots + \beta^* x_{ib} + \dots + \beta_p x_{ip} + \epsilon_i$
 $= \beta_0 + \dots + \beta^* (x_{ia} + x_{ib}) + \dots + \beta_p x_{ip} + \epsilon_i$
 $df_R = n - p$ (제약 조건으로 계수 1개↓)

F-test type III (일반 선형 가설 검정)

- 가설: $H_0 : \beta_a + \beta_b = C$ $H_1 : \beta_a + \beta_b \neq C$
- 모형 재정의 (Full Model)**
 - Full model : $Y_i = \beta_0 + \dots + \beta_a x_{ia} + \dots + \beta_b x_{ib} + \dots + \beta_p x_{ip} + \epsilon_i$
 - $df_F = n - p$ (총 계수 개수가 p)

- 모형 재정의 (Reduced Model)**

- $H_0 : \beta_a = C - \beta_b$ 로 치환
- Reduced model : $Y_i = \beta_0 + \dots + (C - \beta_b) x_{ia} + \dots + \beta_b x_{ib} + \dots + \beta_p x_{ip} + \epsilon_i$
 $\implies Y_i - C x_{ia} = \beta_0 + \beta_1 x_{i1} + \dots + \beta_a (x_{ia} - x_{ib}) + \dots + \beta_p x_{ip} + \epsilon_i$

General Linear Hypothesis (일반 선형 가설)

- 핵심:** 모델을 재추정할 필요 없는 F 검정의 대안 버전이 유도될 수 있다.)

귀무가설과 대립가설 : $H_0 : C_{q \times (p+1)} \beta_{(p+1) \times 1} = \mathbf{h}$
 $H_a : C_{q \times (p+1)} \beta_{(p+1) \times 1} \neq \mathbf{h}$

F-통계량을 통해 검증한 일반 식

- $\mathbf{F} = \frac{(C\hat{\beta} - \mathbf{h})^T (C(X^T X)^{-1} C^T)^{-1} (C\hat{\beta} - \mathbf{h})}{SSE(F)/df_F}$
 $\underset{H_0}{\sim} F(q, n - p - 1)$.
 - 랭크 $\text{rank}(C(X^T X)^{-1} C^T) = q$. 임을 가정하고 있음


예시

- Full Model** : $Y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_5 x_{i5} + \epsilon_i$
- 귀무가설 (Null Hypothesis, H_0)**
 - $\beta_1 + \beta_2 = 0$ $\beta_3 - \beta_4 = 1$ $\beta_1 + \beta_5 = 5$
- 대립가설 (Alternative Hypothesis, H_1)**
 - $H_1 : (H_0 \text{의 적어도 하나의 등식은 성립 X})$
- 일반 선형 가설 행렬 표현 $C\beta = \mathbf{h}$**

$$\circ H_0 : \begin{pmatrix} 0 & 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & -1 & 0 \\ 0 & 1 & 0 & 0 & 0 & 1 \end{pmatrix}_{3 \times 6} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \\ \beta_5 \end{pmatrix}_{6 \times 1} = \begin{pmatrix} 0 \\ 1 \\ 5 \end{pmatrix}_{3 \times 1}$$


$$\circ C\beta = \mathbf{h}$$

10. Diagnostics in multiple linear regression



어떤 것이 틀릴 수 있나?

- 모델에 대한 가정
 - 회귀함수는 틀릴 수 있다 : 만일 회귀 함수가 다른 형태를 가져야만 한다면 (SLR 진단 참조)
- 예측치에 대한 가정
 - 1. 비확률적 예측치일 수 있고, 2) 수집 오차가 있을 수 있다
- 관측치에 대한 가정
 - 몇개의 관측치가 influential하거나 아웃라이어일 수 있다
- 문제를 감지하는건 기술이라기 보단 예술의 영역이다. 회귀식의 모든 가능한 문제에 대해 테스트 할 순 없다



가능한 문제 및 진단 체크

- 오차는 정규분포를 따르지 않을 수 있고, 동일 분산을 가지지 않을 수 있다 (거대 샘플에서는 덜 중요)
- 분산은 상수가 아닐 수 있다. (오차 e가 부채꼴 모양으로 퍼지거나 혹은 추세선이 나타나 분산이 상수항이 아닐 수 있음)
- influential 관측치의 경우 : 어떤 점이 회귀모델에 가장 영향을 주는가?
- 아웃라이어 : 데이터 전처리 실수나 실험 오차등이 포함되어있을 수 있다

내적 스튜던트화 잔차 (Internally Studentized Residuals)

$$r_i = e_i / SE(e_i) = \frac{e_i}{\hat{\sigma} \sqrt{1 - H_{ii}}}$$

- 잔차 e_i 의 정의 및 벡터 표현

$$\begin{aligned} e_i &= Y_i - \hat{Y}_i \rightarrow \begin{pmatrix} e_1 \\ \vdots \\ e_n \end{pmatrix} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} - \begin{pmatrix} \hat{Y}_1 \\ \vdots \\ \hat{Y}_n \end{pmatrix} \\ &= Y - X\hat{\beta} \\ \text{where } \hat{\beta} &= (X^T X)^{-1} X^T Y \end{aligned}$$

- Hat Matrix (H)를 이용한 e 표현

$$\begin{aligned} e &= Y - \underbrace{X(X^T X)^{-1} X^T}_{H} Y \\ &= (I - H)Y = (I - H)(X\beta + e) = (I - H)e \\ &\quad \blacksquare (\because (I - H)X\beta = X\beta - X\beta = 0) \end{aligned}$$

- e 의 기댓값과 공분산 :

$$\begin{aligned} \text{기댓값 : } E(e) &= (I - H)E(\epsilon) = 0 \\ \text{공분산 : } Var(e) &= Var((I - H)\epsilon) = (I - H)Var(\epsilon)(I - H)^T \\ &= (I - H)(\sigma^2 I) = \sigma^2(I - H) \end{aligned}$$

대칭, 멱등

- 잔차와 hat matrix

$$\begin{aligned} \text{기댓값 : } E(e) &\rightarrow (1 - h_{ii})\sigma^2 \text{ (행렬 } I - H \text{의 } i\text{-번째 대각 원소)} \\ \text{표준화된 잔차} &= \frac{e_i}{\sigma \sqrt{1 - h_{ii}}} \\ H &= \begin{pmatrix} h_{11} & \cdots & h_{1n} \\ \vdots & \ddots & \vdots \\ h_{n1} & \cdots & h_{nn} \end{pmatrix}_{n \times n} \end{aligned}$$

외적 스튜던트화 잔차 (Externally Studentized Residuals)

$$t_i = \frac{e_i}{\hat{\sigma}_{(i)} \sqrt{1 - H_{ii}}} \sim t(n - p - 2)$$

관측치 i 를 제외한 추정량 ($\hat{\sigma}_{(i)}^2, \hat{\beta}_{(i)}$)

- 잔차 제곱합 및 분산 추정 :

$$\hat{\sigma}_{(i)}^2 = \frac{SSE_{(i)}}{n - p - 1} \quad SSE_{(i)} = \sum_{j \neq i} (y_j - \hat{y}_{(i)j})^2$$

- i 번째를 제외한 예측값 :

$$\hat{y}_{(i)j} = x_j^T \hat{\beta}_{(i)} = \hat{\beta}_{0(i)} + \hat{\beta}_{1(i)}x_{j1} + \cdots + \hat{\beta}_{p(i)}x_{jp}$$

- $\hat{\beta}_{(i)}$: i 번째 관측치를 제외하고 추정한 회귀계수 추정량.

OLS 추정량과 Leave-One-Out 행렬 정의

- 원래 LSE 를 $\hat{\beta} = (X^T X)^{-1} X^T Y$ 라고 한다면, 관측치 i 를 제외한 행렬 (X_{-i}, Y_{-i}) :

$$X_{-i} = \begin{pmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & & \vdots \\ x_{i-1,1} & \cdots & x_{i-1,p} \\ x_{i+1,1} & \cdots & x_{i+1,p} \\ \vdots & & \vdots \\ x_{n1} & \cdots & x_{np} \end{pmatrix} \quad Y_{-i} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_{i-1} \\ Y_{i+1} \\ \vdots \\ Y_n \end{pmatrix}$$

- $\hat{\beta}_{(i)}$ 공식 (행렬 대수적 근사)

$$\begin{aligned} \hat{\beta}_{(i)} &= (X_{-i}^T X_{-i})^{-1} X_{-i}^T Y_{-i} \\ &= (X^T X - x_i x_i^T)^{-1} (X^T Y - Y_i x_i) \end{aligned}$$

■ 참고: x_i 는 X_i 의 i 번째 행 벡터;
 $x_i^T = (1 \quad x_{i1} \quad \cdots \quad x_{ip})$

예시

- 기본 행렬식 정의:

$$\text{Let, } X = \begin{pmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \\ x_{31} & x_{32} \end{pmatrix} \quad Y = \begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix}$$

- $A^T B$ 형식으로 나타내기

$$\begin{aligned} X^T X &= \begin{pmatrix} \sum_{i=1}^3 x_{i1}^2 & \sum_{i=1}^3 x_{i1} x_{i2} \\ \sum_{i=1}^3 x_{i1} x_{i2} & \sum_{i=1}^3 x_{i2}^2 \end{pmatrix}, \\ X^T Y &= \begin{pmatrix} \sum_{i=1}^3 y_i x_{i1} \\ \sum_{i=1}^3 y_i x_{i2} \end{pmatrix} \end{aligned}$$

- 행벡터의 합과 $X^T X$ 간 관계

$$\begin{aligned} \text{Let,} \\ x_1^T &= (x_{11}, x_{12}) \quad x_2^T = (x_{21}, x_{22}) \quad x_3^T = (x_{31}, x_{32}) \\ x_1 x_1^T &= \begin{pmatrix} x_{11} \\ x_{12} \end{pmatrix} \begin{pmatrix} x_{11} & x_{12} \end{pmatrix} = \begin{pmatrix} x_{11}^2 & x_{11} x_{12} \\ x_{11} x_{12} & x_{12}^2 \end{pmatrix} \\ \sum_{i=1}^3 x_i x_i^T &= x_1 x_1^T + x_2 x_2^T + x_3 x_3^T = X^T X \end{aligned}$$

- $i=2$ 관측치를 제거한 행렬 ($X^T X, X^T Y$ 의 경우)

$$\begin{aligned} X_{-2}^T X_{-2} &= \begin{pmatrix} \sum_{i \neq 2} x_{i1}^2 & \sum_{i \neq 2} x_{i1} x_{i2} \\ \sum_{i \neq 2} x_{i1} x_{i2} & \sum_{i \neq 2} x_{i2}^2 \end{pmatrix} = \\ &X^T X - x_2 x_2^T \quad (\text{참고: } X^T X = \sum_{i=1}^n x_i x_i^T) \\ X_{-2}^T Y_{-2} &= \begin{pmatrix} \sum_{i \neq 2} y_i x_{i1} \\ \sum_{i \neq 2} y_i x_{i2} \end{pmatrix} = X^T Y - y_2 x_2 \\ \text{where } x_2 &= \begin{pmatrix} x_{21} \\ x_{22} \end{pmatrix} \end{aligned}$$

leave 1 out 행렬 관련 성질

1. $\hat{\beta}_{(i)}$

$$= (X^T X - x_i x_i^T)^{-1} (X^T Y - y_i x_i)$$

$$X = \begin{pmatrix} x_1^T \\ \vdots \\ x_n^T \end{pmatrix}_{n \times (p+1)}$$

2. Sherman-Morrison-Woodbury 공식

- 공식 (일반 형태):

$$(A - uu^T)^{-1} = A^{-1} + \frac{A^{-1}uu^T A^{-1}}{1 - u^T A^{-1}u} \quad \text{if } \exists A^{-1}$$

- 공식 적용 (회귀분석):

$$(X^T X - x_i x_i^T)^{-1} = (X^T X)^{-1} + \frac{(X^T X)^{-1} x_i x_i^T (X^T X)^{-1}}{1 - x_i^T (X^T X)^{-1} x_i}$$

$= h_{ii} \cdots (*)$

- (*) H 행렬의 대각 원소 (h_{ii}) 정의

$$\circ I = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} u_1 & u_2 \end{pmatrix}$$

$$\circ u_1^T H u_1 = \begin{pmatrix} 1 & 0 \end{pmatrix} \begin{pmatrix} h_{11} & h_{12} \\ h_{21} & h_{22} \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = h_{11}$$

$$H u_i = \begin{pmatrix} h_{11} & h_{12} \\ h_{21} & h_{22} \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} h_{12} \\ h_{22} \end{pmatrix}$$

$$\circ H(\text{Hat mat.}) = X(X^T X)^{-1} X^T$$

$$\underbrace{u_i^T X}_{=(X^T u_i)^T} (X^T X)^{-1} \underbrace{X^T u_i}_{=x_i(\text{참고})} = x_i^T (X^T X)^{-1} x_i$$

- (참고): $X^T e_i \rightarrow X^T$ 의 i 번째 열
→ 원래 X 의 i 번째 행벡터의 전치 = x_i

3. $\hat{\beta}_{(i)}$

$$= \left((X^T X)^{-1} + \frac{(X^T X)^{-1} x_i x_i^T (X^T X)^{-1}}{1 - h_{ii}} \right) (X^T Y - y_i x_i)$$

$$= \underbrace{(X^T X)^{-1} X^T Y}_{=\hat{\beta}} - y_i \underbrace{(X^T X)^{-1} x_i}_{=\hat{\beta}_{(i)}}$$

$$+ \frac{1}{1 - h_{ii}} (X^T X)^{-1} x_i x_i^T \underbrace{(X^T X)^{-1} X^T Y}_{=\hat{\beta}}$$

$$- \frac{1}{1 - h_{ii}} (X^T X)^{-1} x_i x_i^T \underbrace{(X^T X)^{-1} x_i y_i}_{=h_{ii}}$$

4. $\hat{y}_{j(i)}$

$$= x_j^T \hat{\beta} - x_j^T (X^T X)^{-1} x_i y_i$$

$$+ \frac{1}{1 - h_{ii}} x_j^T (X^T X)^{-1} x_i x_i^T \hat{\beta}$$

$$- \frac{1}{1 - h_{ii}} x_j^T (X^T X)^{-1} x_i h_{ii} y_i$$

$$\circ = x_j^T \hat{\beta} - h_{ij} y_i + \frac{1}{1 - h_{ii}} h_{ij} \hat{y}_i - \frac{1}{1 - h_{ii}} h_{ij} h_{ii} y_i$$

5. $y_j - \hat{y}_{j(i)}$

$$= h_{ij} y_j - \frac{1}{1 - h_{ii}} h_{ij} \hat{y}_i - \frac{1}{1 - h_{ii}} h_{ij} h_{ii} y_i$$

$$= \frac{h_{ij}}{1 - h_{ii}} ((1 - h_{ii}) y_i - \hat{y}_i + h_{ii} y_i) = \frac{h_{ij}}{1 - h_{ii}} (y_i - \hat{y}_i)$$

6. $\sum_{j=1}^n (\hat{Y}_j - \hat{Y}_{j(i)})^2$

$$= \sum_{j=1}^n h_{ij}^2 \left(\frac{e_i}{1 - h_{ii}} \right)^2$$

$$= \frac{e_i^2}{(1 - h_{ii})^2} \cdot \underbrace{\sum_{j=1}^n h_{ij}^2}_{=h_{ii} \cdots (*)} = h_{ii} \cdot \frac{e_i^2}{(1 - h_{ii})^2}$$

- 표준화 잔차 r_i 와 SSE :

$$r_i = \frac{e_i}{\hat{\sigma} \sqrt{1 - h_{ii}}}, \quad r_i^2 = \frac{e_i^2}{\hat{\sigma}^2 (1 - h_{ii})}$$

$$\circ \rightarrow \sum_{j=1}^n (\hat{y}_j - \hat{y}_{j(i)})^2 = h_{ii} \cdot \frac{\hat{\sigma}^2}{(1 - h_{ii})} \frac{e_i^2}{\hat{\sigma}^2 (1 - h_{ii})}$$

$$= \frac{h_{ii}}{1 - h_{ii}} \cdot \hat{\sigma}^2 r_i^2$$

- (*) : Hat Matrix의 성질**

$$\circ (*) \quad \sum_{j=1}^n h_{ij}^2 = h_{ii} \quad (\because H \cdot H = H)$$

$$\text{즉, } (h_{i1} \quad \cdots \quad h_{in}) \begin{pmatrix} h_{1i} \\ \vdots \\ h_{ni} \end{pmatrix} = \sum_{j=1}^n h_{ij}^2 = h_{ii}$$

7. $\frac{1}{\hat{\sigma}^2(p+1)} \sum_{j=1}^n (\hat{Y}_j - \hat{Y}_{j(i)})^2$

$$= \frac{r_i^2}{p+1} \cdot \frac{h_{ii}}{1 - h_{ii}} \rightarrow C_i : \text{Cook's distance.}$$

- 영향력 분석 관련 용어: $\frac{h_{ii}}{1 - h_{ii}}$: potential (잠재력)

8. $\hat{y}_j - \hat{y}_{j(i)} = \frac{h_{ij}}{1 - h_{ii}} \cdot e_i$

9. $y_i - \hat{y}_{i(i)}$

$$= y_i - \hat{y}_i + \hat{y}_i - \hat{y}_{i(i)}$$

$$= e_i + \frac{h_{ii}}{1 - h_{ii}} e_i = \frac{e_i - h_{ii} e_i + h_{ii} e_i}{1 - h_{ii}} = \frac{1}{1 - h_{ii}} e_i$$

10. PRESS

$$= \underbrace{\sum_{i=1}^n (y_i - \hat{y}_{i(i)})^2}_{\text{Leave-one-out cross validation}} = \sum_{i=1}^n \left(\frac{e_i}{1 - h_{ii}} \right)^2 \quad ()$$

11. $y_j - \hat{y}_{j(i)}$

$$= y_j - \hat{y}_j + \hat{y}_j - \hat{y}_{j(i)} = e_j + \frac{h_{ij}}{1 - h_{ii}} e_i$$

12. $SSE_{(i)}$

$$= \sum_{j \neq i}^n (Y_j - \hat{Y}_{j(i)})^2 = \sum_{j \neq i}^n \left(e_j + \frac{h_{ij}}{1 - h_{ii}} e_i \right)^2$$

$$\bullet \sigma_{(i)}^2 = SSE_{(i)} / (n - p - 2)$$

관측치의 영향력 (Influence of an Observation)

- 관측치의 영향력을 측정하기 위한 지표가 있음

1. DFFITS :

$$DFFITS_i = \frac{\hat{Y}_i - \hat{Y}_{i(i)}}{\sigma_{(i)} \sqrt{H_{ii}}}$$

2. Cook's distance :

$$D_i = \frac{\sum_{j=1}^n (\hat{Y}_j - \hat{Y}_{j(i)})^2}{(p+1) \hat{\sigma}^2}$$

3. DFBETAS :

$$DFBETAS_{j(i)} = \frac{\hat{\beta}_j - \hat{\beta}_{j(i)}}{\sqrt{\hat{\sigma}_{(i)}^2 (X^T X)^{-1}_{jj}}}$$

11. Diagnostics in multiple linear regression II

Leverage (레버리지)

- **정의:**
 - $\hat{y} = X\hat{\beta} = \underbrace{X(X'X)^{-1}X'}_H Y$
 - $\hat{y}_i = h_{i1}y_1 + h_{i2}y_2 + \dots + h_{ii}y_i + \dots + h_{in}y_n$
 - $h_{ii} = X_i'(X'X)^{-1}X_i$ (X_i 는 i 번째 row)
 - 의미: i 번째 관측치의 레버리지
- Properties of leverage (레버리지의 성질)
 1. $\frac{1}{n} \leq h_{ii} \leq 1$
 2. $-0.5 \leq h_{ij} \leq 0.5$
 3. $\text{tr}(H) = \sum_{i=1}^n h_{ii} = p + 1$
 - (for model $Y_i = \beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{pi} + \epsilon_i$)

중심화된 관측치 (Centered Observations)

$$Y_i^* = Y_i - \bar{Y}, \quad X_{ij}^* = X_{ij} - \bar{X}_j, \\ \text{where } \bar{X}_j = \frac{1}{n} \sum_{i=1}^n X_{ij}, \quad \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$$

중심화된 관측치를 이용한 모형 (Model with Centered Observations)

- **표현:**
 - $Y_i - \bar{Y} = \beta_1(X_{i1} - \bar{X}_1) + \dots + \beta_p(X_{ip} - \bar{X}_p) + \epsilon_i$
 - $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}_1 - \dots - \hat{\beta}_p \bar{X}_p$

계수 벡터 분리:

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_p \end{pmatrix} \Rightarrow \hat{\beta}_C = \begin{pmatrix} \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_p \end{pmatrix}$$

중심화된 LSE $\hat{\beta}_C$

$$\hat{\beta}_C = (X_C' X_C)^{-1} X_C' (Y - \bar{Y} \mathbf{1}_n)$$

중심화된 설명 변수 행렬 X_C

$$X_C = \begin{pmatrix} X_{11} - \bar{X}_1 & \dots & X_{1p} - \bar{X}_p \\ \vdots & \ddots & \vdots \\ X_{n1} - \bar{X}_1 & \dots & X_{np} - \bar{X}_p \end{pmatrix}_{n \times p}$$

중심화된 행렬의 특성:

- $\mathbf{1}_n' X_C^{(j)} = \sum_{i=1}^n (X_{ij} - \bar{X}_j) = 0$ (각 열 벡터의 합이 0이다.)

$\hat{Y}$ 와 $Y - \bar{Y} \mathbf{1}_n$ 의 관계

$$\begin{aligned} \hat{Y} &= HY = X(X'X)^{-1}X'Y \\ Y - \bar{Y} \mathbf{1}_n & \text{ (중심화된 } Y \text{ 벡터)} \\ &= X_C \hat{\beta}_C = X_C (X_C' X_C)^{-1} X_C' Y \end{aligned}$$

Centered (중심화된) 데이터를 이용한 $\hat{Y}$ 표현

$$\begin{aligned} \hat{Y} &= \bar{Y} \mathbf{1}_n + X_C (X_C' X_C)^{-1} X_C' Y \\ \bar{Y} &= \frac{1}{n} \sum_{i=1}^n Y_i = \frac{1}{n} \mathbf{1}_n' Y \end{aligned}$$

$\hat{Y}$ 전개 및 H 행렬 유도 (증)

$$\hat{Y} = \left(\frac{1}{n} \mathbf{1}_n \mathbf{1}_n' + X_C (X_C' X_C)^{-1} X_C' \right) Y$$

H 행렬 정의

$$\begin{aligned} \Rightarrow H &= X(X'X)^{-1}X' \\ &= \left(\underbrace{\frac{1}{n} \mathbf{1}_n \mathbf{1}_n'}_{\substack{\frac{1}{n} \leq h_{ii} \leq 1}} + \underbrace{X_C (X_C' X_C)^{-1} X_C'}_{H_C} \right) \\ &\quad \text{■ } H_C: \text{대칭행렬, idempotent} \end{aligned}$$

Hat Matrix H 의 성질 유도

$$\mathbf{H} = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n' + H_C$$

1. $h_{ii} \geq \frac{1}{n}$ 유도 (최소값)

- $h_{ii} = e_i' H e_i = e_i' \left(\frac{1}{n} \mathbf{1}_n \mathbf{1}_n' + H_C \right) e_i$
- $e_i : I_n$ 행렬의 i 번째 열 (basis vector)
- $h_{ii} = \frac{1}{n} (e_i' \mathbf{1}_n) (\mathbf{1}_n' e_i) + e_i' H_C e_i$
- $h_{ii} = \frac{1}{n} \cdot 1 \cdot 1 + e_i' H_C e_i$
- $h_{ii} = \frac{1}{n} + e_i' H_C e_i$
 - H_C 는 양의 준정부호 행렬 (Positive Semidefinite Matrix)
 - $e_i' H_C e_i \geq 0$
- $\Rightarrow h_{ii} \geq \frac{1}{n}$

2. $h_{ii} \leq 1$ 유도 (최대값)

- * H 는 멱등 행렬 (Idempotent)

12. interactions and qualitative variable

Two-Group Mean Comparison (Regression Approach)

- **Matrix Formulation ($Y = X\beta + \epsilon$):**
 - Y : 두 그룹 (Z, W)의 결합 벡터.
 - X : 1로 구성된 블록 대각 행렬(Block diagonal with 1s).
 - **Hypothesis:** $H_0 : \beta_1 = \beta_2 \iff H_0 : \mu_1 = \mu_2$
- **Dummy Variable Approach:**
 - Model: $Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$
 - X_i : 그룹 2에 대한 지시 변수(Indicator for Group 2).
 - Interpretation: $\beta_0 = \mu_1, \beta_1 = \mu_2 - \mu_1$.
 - Test: $H_0 : \beta_1 = 0$ 은 동일 평균을 검정하는 것과 동일.

Three-Group Linear Trend Model

- **Model:** $Y_i = \beta_0 + \beta_1 x_i + \epsilon_i$ w/ $x_i \in \{1, 2, 3\}$.
- **Mean Structure:** $\mu_k = \beta_0 + k\beta_1$.
 - **Assumption:** 그룹 인덱스와 평균 간의 선형 관계 가정 ($\mu_{k+1} - \mu_k = \beta_1$).

Three-Group One-Way ANOVA (Regression Formulation)

- **Model:**

$$Y_i = \mu_1 + (\mu_2 - \mu_1)E_{i2} + (\mu_3 - \mu_1)E_{i3} + \epsilon_i$$
- **Matrix Form:** $Y = X\beta + \epsilon$, where $X = [1, E_2, E_3]$.
- **Equivalence:**
 - 회귀에서의 $H_0 : \beta_1 = \beta_2 = 0 \iff$ ANOVA에서의 $H_0 : \mu_1 = \mu_2 = \mu_3$.

Cell Means Model & Perfect Multicollinearity

- **Problem:** 절편(1)과 모든 그룹 지시 변수(E_1, E_2, E_3)를 포함할 경우.
 - $1 = \sum E_i \implies$ 선형 종속(Linear Dependence) $\implies X'X$ 특이 행렬(Singular).
- **Solution (Cell Means Model):** 절편 제거.
 - $Y = (E_1, E_2, E_3)(\mu_1, \mu_2, \mu_3)' + \epsilon$.
 - **hint:** $X'X$ 가 역행렬을 가지려면 열벡터들이 선형 독립이어야 함.

계산 팁 (강의 14-2)

- **Dummy Variable Trap:**
 - k 개 범주 구분 시 반드시 $k - 1$ 개 더미변수만 사용 (상수항 포함 시).
 - **Baseline (Reference):** 더미변수가 모두 0인 그룹. 모든 해석은 Baseline 대비 효과로 해석.

- **Example:** 휘발유(Base), 디젤(E_1), 하이브리드(E_2).
 - $Y = \beta_0 + \beta_1 E_1 + \beta_2 E_2$.
 - 디젤 vs 하이브리드 비교: $H_0 : \beta_1 = \beta_2$.
- **Hypothesis Construction Strategy:**
 - "국산($D = 1$) 하이브리드($H = 1$)가 외제($D = 0$) 디젤($H = 0$)보다 연비가 좋은가?"
 - Model: $Y = \beta_0 + \beta_1 D + \beta_2 H + \beta_3 (D \times H)$.
 - **Construct Means:**
 - 국산 하이브리드: $\beta_0 + \beta_1 + \beta_2 + \beta_3$.
 - 외제 디젤: β_0 . ($H=0$ 이므로 하이브리드 관련 항 0, $D=0$ 이므로 국산 관련 항 0)
 - **Correct Logic (General):** 항상 $E(Y|Condition)$ 을 계수들의 합으로 표현한 뒤 차이를 검정.
- **Pitfall Warning (Causality):**
 - 문제: "무게가 증가할수록 연비가 감소하는가?"
 - 모델 선택 시 $Y = \text{연비}$, $X = \text{무게}$ 인 모델을 골라야 함. 반대로 $Y = \text{무게}$ 인 모델(Model D in Audio)은 인과관계가 반대이므로 기각.

salary example (stratification)

- 매니저 여부, 학력수준 (고/대/석)을 $2 \times 3 = 6$ 가지 케이스 중 각 E와 M의 조합에 따라 모델을 6개로 분리

Use qualitative variables (케이스마다 서로 다른 절편)

- 또는 6가지의 경우의 수를 dummy variable을 사용해 나타낼 수 있음
 - (각 관측치는 동분산 σ^2 을 가정)
 - $S_i = \beta_0 + \beta_1 X_i + \beta_2 E_{i2} + \beta_3 E_{i3} + \beta_4 M_i + \epsilon_i$
 - $E_{i2} = \begin{cases} 1 & \text{if } E_i = 2 \\ 0 & \text{otherwise,} \end{cases} \quad E_{i3} = \begin{cases} 1 & \text{if } E_i = 3 \\ 0 & \text{otherwise,} \end{cases}$
 - $M_i = \begin{cases} 1 & \text{if } M \\ 0 & \text{otherwise.} \end{cases}$
- 절편에 dummy var 추가 시: 경우의 수가 3개라면, 하나를 디폴트 케이스, dummy var은 2개만 쓴다

Interactions (케이스마다 서로 다른 기울기)

$$S_i = \beta_0 + \beta_1 X_i + \beta_2 E_{i2} + \beta_3 E_{i3} + \beta_4 M_i + \beta_5 E_{i2} X_i + \beta_6 E_{i3} X_i + \epsilon_i$$

Connection to One-way ANOVA

- **Regression with Dummy Variables $\approx$ One-way ANOVA**
 - 더미 변수를 이용한 회귀는 One-way ANOVA와 수학적으로 동치.
- **가설 검정**
 - $H_0 : \beta_2 = \beta_3 = \dots = 0$ (모든 더미 계수가 0)
 - $\iff H_0 : \mu_1 = \mu_2 = \dots = \mu_k$ (모든 그룹 평균이 동일)
 - F-test (Partial F-test)를 사용하여 검정.

14. Correlated Errors

AutoCorrelation & AR(1) Process

- **AR(1)** Model:
 $\epsilon_t = \rho\epsilon_{t-1} + w_t, \quad |\rho| < 1, \quad w_t \sim iidN(0, \sigma^2)$
- **Properties (Stationarity assumed):**
 - $E(\epsilon_t) = 0$
 - $Var(\epsilon_t) = \frac{\sigma^2}{1-\rho^2}$
 - **hint:** $\epsilon_t = \sum \rho^k w_{t-k}$ 로 전개하고 무한 등비 급수 분산 합 이용.
 - $Cov(\epsilon_t, \epsilon_{t-k}) = \rho^k \frac{\sigma^2}{1-\rho^2}$
 - $Corr(\epsilon_t, \epsilon_{t-k}) = \rho^k$

Durbin-Watson Statistic (d)

- **Definition:** $d = \frac{\sum (e_t - e_{t-1})^2}{\sum e_t^2}$
- **Approximation:** $d \approx 2(1 - \hat{\rho})$
 - **hint:** 분자 $\sum e_t^2 + \sum e_{t-1}^2 - 2 \sum e_t e_{t-1}$ 전개 및 큰 n 에 대해 $\sum e_t^2 \approx \sum e_{t-1}^2$ 가정.
- **Decision Rules:**
 - $\hat{\rho} \approx 0 \implies d \approx 2$ (자기상관 없음).
 - $\hat{\rho} > 0 \implies d < 2$ (양의 상관).
 - $\hat{\rho} < 0 \implies d > 2$ (음의 상관).
 - 임계값 d_L, d_U 사용.

Regression with Autocorrelated Errors (Transformation)

- **Model:** $y_t = \beta_0 + \beta_1 x_t + \epsilon_t$ with AR(1) errors.
- **Transformed Variables (y^*, x^*):**
 - $y_t^* = y_t - \rho y_{t-1}$
 - $x_t^* = x_t - \rho x_{t-1}$
- **Resulting Model:** $y_t^* = \beta_0(1 - \rho) + \beta_1 x_t^* + w_t$
 - 오차항 w_t 는 이제 iid $N(0, \sigma^2)$ 임 (OLS 적용 가능).
 - **Simultaneous Estimation:** ρ, β 에 대해 $\sum (y_t - \rho y_{t-1} - \dots)^2$ 를 최소화 가능 (Grid Search).

ρ 의 추정 (Unknown ρ)

- **Cochrane-Orcutt 절차 (반복법):**
 1. 원본 데이터에 OLS 수행 ($y_t = \beta_0 + \beta_1 x_t + \epsilon_t$).
 2. 잔차 e_t 를 얻고 $\frac{\sum e_t e_{t-1}}{\sum e_{t-1}^2}$ 를 이용해 $\hat{\rho}$ 추정.
 3. 데이터 변환:
 $y_t^* = y_t - \hat{\rho} y_{t-1}, \quad x_t^* = x_t - \hat{\rho} x_{t-1}$.
 4. 변환된 데이터에 OLS를 수행하여 $\hat{\beta}$ 업데이트.
 5. 수렴할 때까지 반복.
- **탐색 방법 (Grid Search):**
 - ρ 고정 (예: 0, 0.01, ..., 0.99).
 - 고정된 ρ 에 대해 SSE를 최소화하는 β 찾기.
 - 전역 최소 SSE를 주는 ρ 선택.
 - **hint:** ρ 가 고정되면 β 추정은 Convex OLS 문제임.

Generalized Least Squares (GLS)

- **Assumption:** $Var(\epsilon) = \Sigma$ (비대각, Non-diagonal).
- **Spectral Decomposition:** $\Sigma = UDU'$
 - 변환 행렬: $S = \Sigma^{-1/2} = UD^{-1/2}U'$
- **Transformed** Model:
 $\tilde{Y} = SY, \quad \tilde{X} = SX, \quad \tilde{\epsilon} = S\epsilon$
 - $Var(\tilde{\epsilon}) = S\Sigma S' = I$ (등분산성 회복, Homoscedasticity restored).
- **GLS Estimator:** $\hat{\beta}_{GLS} = (X'\Sigma^{-1}X)^{-1}X'\Sigma^{-1}Y$
 - **hint:** 변환된 $\tilde{Y}, \tilde{X}$ 에 OLS 적용.

Durbin-Watson Statistic (d)

- **Definition:** $d = \frac{\sum (e_t - e_{t-1})^2}{\sum e_t^2}$
- **Approximation:** $d \approx 2(1 - \hat{\rho})$
 - **hint:** Expand numerator $\sum e_t^2 + \sum e_{t-1}^2 - 2 \sum e_t e_{t-1}$ and assume $\sum e_t^2 \approx \sum e_{t-1}^2$ for large n .
- **Decision Rules:**
 - $\hat{\rho} \approx 0 \implies d \approx 2$ (No Autocorrelation).
 - $\hat{\rho} > 0 \implies d < 2$ (Positive).
 - $\hat{\rho} < 0 \implies d > 2$ (Negative).
 - Use critical values d_L, d_U .

Regression with Autocorrelated Errors (Transformation)

- **Model:** $y_t = \beta_0 + \beta_1 x_t + \epsilon_t$ with AR(1) errors.
- **Transformed Variables (y^*, x^*):**
 - $y_t^* = y_t - \rho y_{t-1}$
 - $x_t^* = x_t - \rho x_{t-1}$
- **Resulting Model:** $y_t^* = \beta_0(1 - \rho) + \beta_1 x_t^* + w_t$
 - Error term w_t is now iid $N(0, \sigma^2)$ (OLS applicable).
 - **Simultaneous Estimation:** Can optimize $\sum (y_t - \rho y_{t-1} - \dots)^2$ over ρ, β (Grid Search).

Estimation of ρ (Unknown ρ)

- **Cochrane-Orcutt Procedure (Iterative):**
 1. Run OLS on original data ($y_t = \beta_0 + \beta_1 x_t + \epsilon_t$).
 2. Obtain residuals e_t and estimate $\hat{\rho}$ using $\frac{\sum e_t e_{t-1}}{\sum e_{t-1}^2}$.

3. Transform

$$y_t^* = y_t - \hat{\rho} y_{t-1}, \quad x_t^* = x_t - \hat{\rho} x_{t-1}.$$

data:

4. Run OLS on transformed data to updated $\hat{\beta}$.

5. Iterate until convergence.

- **Search Method (Grid Search):**
 - Fix ρ (e.g., 0, 0.01, ..., 0.99).
 - Find β minimizing SSE for that fixed ρ .
 - Select ρ that gives global minimum SSE.
 - **hint:** ρ 가 고정되면 β 추정은 Convex OLS 문제임.

Generalized Least Squares (GLS)

- **Assumption:** $\text{Var}(\epsilon) = \Sigma$ (Non-diagonal).
- **Spectral Decomposition:** $\Sigma = UDU'$
 - Transformation Matrix: $S = \Sigma^{-1/2} = UD^{-1/2}U'$
- **Transformed Model:**
 $\tilde{Y} = SY, \quad \tilde{X} = SX, \quad \tilde{\epsilon} = S\epsilon$
 - $\text{Var}(\tilde{\epsilon}) = S\Sigma S' = I$ (Homoscedasticity restored).
- **GLS Estimator:** $\hat{\beta}_{GLS} = (X'\Sigma^{-1}X)^{-1}X'\Sigma^{-1}Y$
 - **hint:** Just Apply OLS to transformed $\tilde{Y}, \tilde{X}$.

15. Model Selection

Outline (Model Selection)

- 회귀 상황에서 Y 와 X 가 centered 되었다 가정 : $Y_{(n \times 1)} = X_{(n \times p)}\beta_{(p \times 1)} + \epsilon_{(n \times 1)}$
- 부분집합 $A \subset \{1, \dots, p\}$ 에 대해 새 회귀 모형 : $M(A) : Y_{(n \times 1)} = X[:, A]\beta[A] + \epsilon_{(n \times 1)}$
 - $(\beta[A^c] = 0)$ 라 세팅; 총 가능한 모델선택은 2^p
 - 모델선택 $\rightarrow$ 1) 어떤 기준? 2) 어떻게 탐색?(p 가 크면 전수조사 어렵)

Problem & Goals (문제 및 목표)

- x_1, x_2, x_3 에 대해, $x_3 = [x_{31}, \dots, x_{39}]$; 가능한 모델 갯수=29
 - $x_1, x_2, x_{31}, \dots, x_{39} \rightarrow 11$ 개;
 - $x_1x_{31}, \dots, x_1x_{39} \rightarrow 9$ 개
 - $x_2x_{31}, \dots, x_2x_{39} \rightarrow 9$ 개
 - main effect(1) + interactions (2),(3)

Justifying parsimony (검약성의 정당성)

- Principle of parsimony(오컴의 면도날)
 - p 개의 설명변수로 설명 가능한 모델보단 $j(j < p)$ 개의 설명변수로 설명 가능한 모델이 최선.
- 예시) (model 1) : $Y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \epsilon_i; (\beta_2 = 0)$
 - $Var(\hat{\beta}_1^{M1}) = \sigma^2((X'X)^{-1})_{11}$

$$= \frac{\sigma^2 S_{2,2}}{S_{1,1}S_{2,2} - S_{1,2}^2}$$
 - hint : let $S_{a,b} = \sum_{i=1}^n x_{ia}x_{ib}$; $X, X'X, X'Y$ 행렬 정의, 역행렬 정의
- (model 2) : $Y_i = \beta_1 x_{i1} + \epsilon_i; Var(\hat{\beta}_1^{M2}) = \frac{\sigma^2}{S_{1,1}}$
 - $Var(\hat{\beta}_1^{M1})/Var(\hat{\beta}_1^{M2})$

$$= 1 + \frac{S_{1,2}^2}{S_{1,1}S_{2,2} - S_{1,2}^2} \geq 1$$
 - hint : 코시-슈바르츠 부등식 : $S_{1,1}S_{2,2} \geq S_{1,2}^2$

Candidate criteria (후보 기준)

Candidate criteria

- R^2 : 좋은 평가 지표X; 단순히 파라미터 갯수가 늘어도 증가함
- $adj. R^2$: 더 나은 평가 지표; 과적합을 일부 방지;
- Mallow's C_p : 모델의 예측력을 평가함 (새 관측치에 대한 예측력)
- (실무) : AIC(예측), BIC(true model), Cross-validation 등 평가 지표

Mallow's C_p

- $C_p(M) = \frac{SSE(M)}{\hat{\sigma}^2} + 2p_M - n$ (p_M : # of params in Model)
 - $= \frac{S_A - \hat{\sigma}^2}{\hat{\sigma}^2/(n-p_M)} + p_M$
if $S_A^2 \rightarrow \hat{\sigma}^2$, then $C_p(M(A)) \rightarrow p_M$
 - hint : $S_A^2 = SSE(M(A))/(n-p_M)$ 라 하자; p_M : 모델 M의 예측변수 개수.

AIC (Akaike Information Criterion) 유도 (Derivation)

- Likelihood Function ($L(\beta)$):**
 - Model: $Y_i = x_i'\beta + \epsilon_i, \epsilon_i \sim iid N(0, \sigma^2)$
 - $L(\beta) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum (y_i - x_i'\beta)^2\right\}$
- Log-Likelihood:**
 - $\log L(\beta) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} SSE$
- AIC Definition:**
 - $AIC = -2 \log L(\hat{\beta}) + 2p$
 - MLE $\hat{\sigma}^2 = SSE/n$ 이용:
 - $-2 \log L(\hat{\beta}) = n \log(2\pi\hat{\sigma}^2) + \frac{1}{\hat{\sigma}^2} SSE = n \log(2\pi\hat{\sigma}^2) + n$
 - $\Rightarrow AIC = n \log(SSE/n) + 2p + \text{const}$ (상수는 비교 시 종종 무시됨).

Search strategies (탐색 전략)

start	step 1	...	step p
$Y_i = \beta_0 + \epsilon_i$	$+X_1$		
	$\vdots$	$\Rightarrow$	1스텝에 1개씩 추가
(Forward Selection)	$+X_p$		개선X? stop

•

start	step 1	...	step p
$Y_i = \beta_0 + \sum_{j=1}^p \beta_j X_{ij} + \epsilon_i$	$-X_1$		
	$\vdots$	$\Rightarrow$	1스텝에 1개씩 추가
(Backward Elimination)	$-X_p$		개선X? stop

•

•

•

start	step 1	step 2	...	step p
	ex) forward	ex) X_1 choice		
(Forward or Backward)	$+X_1$	$+X_2$		
	$+X_2$	$\vdots$	$\Rightarrow$	for, back 둘 중 하나 따름
	$\vdots$	$+X_p$		다음 스텝에 이전 걸 뺄지 결정
(Stepwise Selection)	$+X_p$	(선택 : $-X_1$)		

- 계산비용 : 총 p개의 step중 step j에서 p-j+1개의 모형 적합

- (모형의 수)

$$= \sum_{j=1}^p p - j + 1 = \sum_{j=1}^p j = p(p+1)/2$$

16. Penalized Regression

다중공선성 진단 (Multicollinearity Diagnostics)

- **VIF (분산 팽창 요인):**
 - $VIF_j = \frac{1}{1-R_j^2}$
 - R_j^2 : X_j 를 다른 설명변수들에 대해 회귀했을 때의 R^2 .
 - **Criterion:** $VIF > 10 \implies$ Severe(심각).
- **Condition Number (k):**
 - $k = \sqrt{\frac{\lambda_{max}}{\lambda_{min}}}$, 여기서 λ 는 $X'X$ (또는 상관 행렬)의 고유값.
 - **Criterion:** $k > 15 \sim 30 \implies$ Problematic(문제 있음).

Penalized Regression Concepts

- **Idea:** MSE를 최소화하기 위해 편향(Bias)을 희생하여 분산(Variance)을 낮추는 상충 관계(Trade-off) 활용.

- **Ridge Regression (L_2 Penalty):**
 - Minimize: $\sum (y_i - x_i' \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2$
 - **Effect:** 계수를 0으로 수축시키지만 완전히 0이 되지는 않음. 다중공선성 해결 ($X'X + \lambda I$ 역행렬 존재).
- **Lasso Regression (L_1 Penalty):**
 - Minimize: $\sum (y_i - x_i' \beta)^2 + \lambda \sum_{j=1}^p |\beta_j|$
 - **Effect:** 계수를 **정확히 0**으로 수축 가능 (변수 선택).
 - **Geometry:** 제약 영역이 다이아몬드($\diamond$) 형태. 코너 솔루션(Corner solution) 발생 가능성 높음.
- **Bias-Variance Trade-off:**
 - $MSE = Bias^2 + Variance$.
 - 벌점 모델은 편향($\lambda > 0$, 0으로 편향된 추정)을 도입하지만 분산을 크게 줄여 종종 더 낮은 MSE를 유도함.
 - **hint:** OLS는 비편향($Bias=0$)이지만 분산이 클 수 있음 (특히 다중공선성 존재 시). 벌점화는 약간의 편향을 대가로 큰 분산 감소를 얻음.