

9. Multiple regression 3

inference for multiple regression

1개 이상 변수를 Dropping 하는 과정

- 귀무가설과 대립가설
 $H_0 : \beta_6 = \beta_7 = 0 \quad H_1 : \text{one of } \beta_6, \beta_7 \text{ is not } 0$
- 검정 방법: 두 모형간 비교
 - Reduced Model :
 $\text{Reduced}(H_0) : Y_i = \beta_0 + \sum_{j=1}^5 \beta_j X_{ij} + \epsilon_i$
 - Full Model :
 $\text{Full}(H_1) : Y_i = \beta_0 + \sum_{j=1}^7 \beta_j X_{ij} + \epsilon_i$
 - (F-val) $\geq F_\alpha(2, n - p - 1)$ 일때 H_0 를 기각

F-test 유형별 가설 설정 및 모형 비교

F-test type I (모형의 유의성 검정)

- 가설: $H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0 \quad H_1 : \exists \beta_k \neq 0$
 $k \in \{i_1, \dots, i_j\} \subset \{0, 1, \dots, p\}$

F-test type II (두 계수의 동일성 검정)

- 가설: $H_0 : \beta_a = \beta_b (\beta^*) \quad H_1 : \beta_a \neq \beta_b$
- 모형 재정의 (Full Model)
 - Full model : $Y_i = \beta_0 + \dots + \beta_a x_{ia} + \dots + \beta_b x_{ib} + \dots + \beta_p x_{ip} + \epsilon_i \quad df_F = n - p - 1$
- 모형 재정의 (Reduced Model)
 - $H_0 : \beta_a = \beta_b = \beta^*$ 로 치환 ($\beta_b = \beta^*$)
 - Reduced model : $Y_i = \beta_0 + \dots + \beta^* x_{ia} + \dots + \beta^* x_{ib} + \dots + \beta_p x_{ip} + \epsilon_i$
 $= \beta_0 + \dots + \beta^* (x_{ia} + x_{ib}) + \dots + \beta_p x_{ip} + \epsilon_i$
 $df_R = n - p$ (제약 조건으로 계수 1개↓)

F-test type III (일반 선형 가설 검정)

- 가설: $H_0 : \beta_a + \beta_b = C \quad H_1 : \beta_a + \beta_b \neq C$
- 모형 재정의 (Full Model)
 - Full model : $Y_i = \beta_0 + \dots + \beta_a x_{ia} + \dots + \beta_b x_{ib} + \dots + \beta_p x_{ip} + \epsilon_i$
 - $df_F = n - p$ (총 계수 개수가 p)

모형 재정의 (Reduced Model)

- $H_0 : \beta_a = C - \beta_b$ 로 치환
- Reduced model : $Y_i = \beta_0 + \dots + (C - \beta_b) x_{ia} + \dots + \beta_b x_{ib} + \dots + \beta_p x_{ip} + \epsilon_i$
 $\implies Y_i - C x_{ia} = \beta_0 + \beta_1 x_{i1} + \dots + \beta_a (x_{ia} - x_{ib}) + \dots + \beta_p x_{ip} + \epsilon_i$
- $df_R = n - (p - 1)$ (제약 조건 $\beta_a + \beta_b = C$ 로 계수가 1개 줄어듦)

General Linear Hypothesis (일반 선형 가설)

- 핵심:** 모델을 재추정할 필요 없는 F 검정의 대안 버전이 유도될 수 있다.)

귀무가설과 대립가설 : $H_0 : C_{q \times (p+1)} \beta_{(p+1) \times 1} = \mathbf{h}$
 $H_a : C_{q \times (p+1)} \beta_{(p+1) \times 1} \neq \mathbf{h}$

F-통계량을 통해 검증한 일반 식

- $\mathbf{F} = \frac{(C\hat{\beta} - \mathbf{h})^T (C(X^T X)^{-1} C^T)^{-1} (C\hat{\beta} - \mathbf{h}) / q}{SSE(F) / df_F}$
 $\underset{H_0}{\sim} F(q, n - p - 1)$
 - 랭크 $\text{rank}(C(X^T X)^{-1} C^T) = q$. 임을 가정하고 있음


예시

- Full Model : $Y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_5 x_{i5} + \epsilon_i$
- 귀무가설 (Null Hypothesis, H_0)
 - $\beta_1 + \beta_2 = 0 \quad \beta_3 - \beta_4 = 1 \quad \beta_1 + \beta_5 = 5$
- 대립가설 (Alternative Hypothesis, H_1)
 - $H_1 : (H_0 \text{의 적어도 하나의 등식은 성립 X})$
- 일반 선형 가설 행렬 표현 $C\beta = \mathbf{h}$

$$\circ H_0 : \begin{pmatrix} 0 & 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & -1 & 0 \\ 0 & 1 & 0 & 0 & 0 & 1 \end{pmatrix}_{3 \times 6} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \\ \beta_5 \end{pmatrix}_{6 \times 1} = \begin{pmatrix} 0 \\ 1 \\ 5 \end{pmatrix}_{3 \times 1}$$


$$\circ C\beta = \mathbf{h}$$

10. Diagnostics in multiple linear regression



어떤 것이 틀릴 수 있나?

- 모델에 대한 가정
 - 회귀함수는 틀릴 수 있다 : 만일 회귀 함수가 다른 형태를 가져야만 한다면 (SLR 진단 참조)
- 예측치에 대한 가정
 - 1. 비확률적 예측치일 수 있고, 2) 수집 오차가 있을 수 있다
- 관측치에 대한 가정
 - 몇개의 관측치가 influential하거나 아웃라이어일 수 있다
- 문제를 감지하는건 기술이라기 보단 예술의 영역이다. 회귀식의 모든 가능한 문제에 대해 테스트 할 순 없다



가능한 문제 및 진단 체크

- 오차는 정규분포를 따르지 않을 수 있고, 동일 분산을 가지지 않을 수 있다 (거대 샘플에서는 덜 중요)
- 분산은 상수가 아닐 수 있다. (오차 e가 부채꼴 모양으로 퍼지거나 혹은 추세선이 나타나 분산이 상수항이 아닐 수 있음)
- influential 관측치의 경우 : 어떤 점이 회귀모델에 가장 영향을 주는가?

- 아웃라이어 : 데이터 전처리 실수나 실험 오차등이 포함 되어있을 수 있다

Internally studentized residuals

$$r_i = e_i / SE(e_i) = \frac{e_i}{\hat{\sigma} \sqrt{1 - H_{ii}}}$$

- 잔차 e_i 의 정의 및 벡터 표현

$$e_i = Y_i - \hat{Y}_i \rightarrow \begin{pmatrix} e_1 \\ \vdots \\ e_n \end{pmatrix} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} - \begin{pmatrix} \hat{Y}_1 \\ \vdots \\ \hat{Y}_n \end{pmatrix}$$

$$= Y - X\hat{\beta}$$

$$\text{where } \hat{\beta} = (X^T X)^{-1} X^T Y$$

- Hat Matrix (H)를 이용한 e 표현

$$e = Y - \underbrace{X(X^T X)^{-1} X^T}_{H} Y$$

$$= (I - H)Y = (I - H)(X\beta + e) = (I - H)e$$

$$\blacksquare (\because (I - H)X\beta = X\beta - X\beta = 0)$$

- e 의 기댓값과 공분산 :

$$\circ \text{기댓값} : E(e) = (I - H)E(\epsilon) = 0$$

$$\circ \text{Var}(e) = \text{Var}((I - H)\epsilon) = (I - H)\text{Var}(\epsilon)(I - H)^T$$

대칭, 멱등

$$= (I - H)(\sigma^2 I) = \sigma^2(I - H)$$

- 잔차와 hat matrix

$$\circ \text{Var}(\epsilon_i) \rightarrow (1 - h_{ii})\sigma^2 \text{ (행렬 } I - H \text{의 } i\text{-번째 대각 원소)}$$

$$\circ \frac{e_i}{\sigma \sqrt{1 - h_{ii}}} \text{ (표준화된 잔차)}$$

$$\circ H = \begin{pmatrix} h_{11} & \cdots & h_{1n} \\ \vdots & \ddots & \vdots \\ h_{n1} & \cdots & h_{nn} \end{pmatrix}_{n \times n}$$

Externally studentized residuals

$$t_i = \frac{e_i}{\hat{\sigma}_{(i)} \sqrt{1 - H_{ii}}} \sim t(n - p - 2)$$

관측치 i 를 제외한 추정량 ($\hat{\sigma}_{(i)}^2, \hat{\beta}_{(i)}$)

- 잔차 제곱합 및 분산 추정 :

$$\hat{\sigma}_{(i)}^2 = \frac{SSE_{(i)}}{n - p - 1} = \frac{SSE_{(i)}}{n - p - 1}$$

- i 번째를 제외한 예측값 :

$$\hat{y}_{(i)j} = x_j^T \hat{\beta}_{(i)} = \hat{\beta}_{0(i)} + \hat{\beta}_{1(i)}x_{j1} + \cdots + \hat{\beta}_{p(i)}x_{jp}$$

- $\hat{\beta}_{(i)}$: i 번째 관측치를 제외하고 추정한 회귀계수 추정량.

OLS 추정량과 Leave-One-Out 행렬 정의

- 원래 LSE 를 $\hat{\beta} = (X^T X)^{-1} X^T Y$ 라고 한다면, 관측치 i 를 제외한 행렬 (X_{-i}, Y_{-i}) :

$$X_{-i} = \begin{pmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & & \vdots \\ x_{i-1,1} & \cdots & x_{i-1,p} \\ x_{i+1,1} & \cdots & x_{i+1,p} \\ \vdots & & \vdots \\ x_{n1} & \cdots & x_{np} \end{pmatrix} \quad Y_{-i} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_{i-1} \\ Y_{i+1} \\ \vdots \\ Y_n \end{pmatrix}$$

- $\hat{\beta}_{(i)}$ 공식 (행렬 대수적 근사)

$$\begin{aligned} \hat{\beta}_{(i)} &= (X_{-i}^T X_{-i})^{-1} X_{-i}^T Y_{-i} \\ &= (X^T X - x_i x_i^T)^{-1} (X^T Y - Y_i x_i) \end{aligned}$$

■ 참고: x_i 는 X_i 의 i 번째 행 벡터;
 $x_i^T = (1 \quad x_{i1} \quad \cdots \quad x_{ip})$

예시

- 기본 행렬식 정의:

$$\text{Let, } X = \begin{pmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \\ x_{31} & x_{32} \end{pmatrix} \quad Y = \begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix}$$

- $A^T B$ 형식으로 나타내기

$$\begin{aligned} X^T X &= \begin{pmatrix} \sum_{i=1}^3 x_{i1}^2 & \sum_{i=1}^3 x_{i1} x_{i2} \\ \sum_{i=1}^3 x_{i1} x_{i2} & \sum_{i=1}^3 x_{i2}^2 \end{pmatrix}, \\ X^T Y &= \begin{pmatrix} \sum_{i=1}^3 y_i x_{i1} \\ \sum_{i=1}^3 y_i x_{i2} \end{pmatrix} \end{aligned}$$

- 행벡터의 합과 $X^T X$ 간 관계

$$\begin{aligned} \text{Let,} \\ x_1^T &= (x_{11}, x_{12}) \quad x_2^T = (x_{21}, x_{22}) \quad x_3^T = (x_{31}, x_{32}) \\ x_1 x_1^T &= \begin{pmatrix} x_{11} \\ x_{12} \end{pmatrix} \begin{pmatrix} x_{11} & x_{12} \end{pmatrix} = \begin{pmatrix} x_{11}^2 & x_{11} x_{12} \\ x_{11} x_{12} & x_{12}^2 \end{pmatrix} \\ \sum_{i=1}^3 x_i x_i^T &= x_1 x_1^T + x_2 x_2^T + x_3 x_3^T = X^T X \end{aligned}$$

- $i=2$ 관측치를 제거한 행렬 ($X^T X, X^T Y$ 의 경우)

$$\begin{aligned} X_{-2}^T X_{-2} &= \begin{pmatrix} \sum_{i \neq 2} x_{i1}^2 & \sum_{i \neq 2} x_{i1} x_{i2} \\ \sum_{i \neq 2} x_{i1} x_{i2} & \sum_{i \neq 2} x_{i2}^2 \end{pmatrix} = \\ &X^T X - x_2 x_2^T \quad (\text{참고: } X^T X = \sum_{i=1}^n x_i x_i^T) \\ X_{-2}^T Y_{-2} &= \begin{pmatrix} \sum_{i \neq 2} y_i x_{i1} \\ \sum_{i \neq 2} y_i x_{i2} \end{pmatrix} = X^T Y - y_2 x_2 \\ \text{where } x_2 &= \begin{pmatrix} x_{21} \\ x_{22} \end{pmatrix} \end{aligned}$$

leave 1 out 행렬 관련 성질

1. $\hat{\beta}_{(i)}$

$$= (X^T X - x_i x_i^T)^{-1} (X^T Y - y_i x_i)$$

$$X = \begin{pmatrix} x_1^T \\ \vdots \\ x_n^T \end{pmatrix}_{n \times (p+1)}$$

2. Sherman-Morrison-Woodbury 공식

- 공식 (일반 형태):

$$(A - uu^T)^{-1} = A^{-1} + \frac{A^{-1}uu^T A^{-1}}{1 - u^T A^{-1}u} \quad \text{if } \exists A^{-1}$$

- 공식 적용 (회귀분석):

$$(X^T X - x_i x_i^T)^{-1} = (X^T X)^{-1} + \frac{(X^T X)^{-1} x_i x_i^T (X^T X)^{-1}}{1 - x_i^T (X^T X)^{-1} x_i}$$

$= h_{ii} \cdots (*)$

- (*) H 행렬의 대각 원소 (h_{ii}) 정의

$$\circ I = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} u_1 & u_2 \end{pmatrix}$$

$$\circ u_1^T H u_1 = \begin{pmatrix} 1 & 0 \end{pmatrix} \begin{pmatrix} h_{11} & h_{12} \\ h_{21} & h_{22} \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = h_{11}$$

$$H u_i = \begin{pmatrix} h_{11} & h_{12} \\ h_{21} & h_{22} \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} h_{12} \\ h_{22} \end{pmatrix}$$

$$\circ H(\text{Hat mat.}) = X(X^T X)^{-1} X^T$$

$$\underbrace{u_i^T X}_{=(X^T u_i)^T} (X^T X)^{-1} \underbrace{X^T u_i}_{=x_i(\text{참고})} = x_i^T (X^T X)^{-1} x_i$$

- (참고): $X^T e_i \rightarrow X^T$ 의 i 번째 열
→ 원래 X 의 i 번째 행벡터의 전치 = x_i

3. $\hat{\beta}_{(i)}$

$$= \left((X^T X)^{-1} + \frac{(X^T X)^{-1} x_i x_i^T (X^T X)^{-1}}{1 - h_{ii}} \right) (X^T Y - y_i x_i)$$

$$= \underbrace{(X^T X)^{-1} X^T Y}_{=\hat{\beta}} - y_i \underbrace{(X^T X)^{-1} x_i}_{=\hat{\beta}_{(i)}}$$

$$+ \frac{1}{1 - h_{ii}} (X^T X)^{-1} x_i x_i^T \underbrace{(X^T X)^{-1} X^T Y}_{=\hat{\beta}}$$

$$- \frac{1}{1 - h_{ii}} (X^T X)^{-1} x_i x_i^T \underbrace{(X^T X)^{-1} x_i y_i}_{=h_{ii}}$$

4. $\hat{y}_{j(i)}$

$$= x_j^T \hat{\beta} - x_j^T (X^T X)^{-1} x_i y_i$$

$= h_{ij}$

$$+ \frac{1}{1 - h_{ii}} x_j^T (X^T X)^{-1} x_i x_i^T \hat{\beta}$$

$= h_{ij} \quad = \hat{y}_i$

$$- \frac{1}{1 - h_{ii}} x_j^T (X^T X)^{-1} x_i h_{ii} y_i$$

$= h_{ij}$

$$\circ = x_j^T \hat{\beta} - h_{ij} y_i + \frac{1}{1 - h_{ii}} h_{ij} \hat{y}_i - \frac{1}{1 - h_{ii}} h_{ij} h_{ii} y_i$$

5. $y_j - \hat{y}_{j(i)}$

$$= h_{ij} y_j - \frac{1}{1 - h_{ii}} h_{ij} \hat{y}_i - \frac{1}{1 - h_{ii}} h_{ij} h_{ii} y_i$$

$$= \frac{h_{ij}}{1 - h_{ii}} ((1 - h_{ii}) y_i - \hat{y}_i + h_{ii} y_i) = \frac{h_{ij}}{1 - h_{ii}} (y_i - \hat{y}_i)$$

6. $\sum_{j=1}^n (\hat{Y}_j - \hat{Y}_{j(i)})^2$

$$= \sum_{j=1}^n h_{ij}^2 \left(\frac{e_i}{1 - h_{ii}} \right)^2$$

$$= \frac{e_i^2}{(1 - h_{ii})^2} \cdot \underbrace{\sum_{j=1}^n h_{ij}^2}_{=h_{ii} \cdots (*)} = h_{ii} \cdot \frac{e_i^2}{(1 - h_{ii})^2}$$

- 표준화 잔차 r_i 와 SSE :

$$r_i = \frac{e_i}{\hat{\sigma} \sqrt{1 - h_{ii}}}, \quad r_i^2 = \frac{e_i^2}{\hat{\sigma}^2 (1 - h_{ii})}$$

$$\circ \rightarrow \sum_{j=1}^n (\hat{y}_j - \hat{y}_{j(i)})^2 = h_{ii} \cdot \frac{\hat{\sigma}^2}{(1 - h_{ii})} \frac{e_i^2}{\hat{\sigma}^2 (1 - h_{ii})}$$

$$= \frac{h_{ii}}{1 - h_{ii}} \cdot \hat{\sigma}^2 r_i^2$$

- (*) : Hat Matrix의 성질**

$$\circ (*) \quad \sum_{j=1}^n h_{ij}^2 = h_{ii} \quad (\because H \cdot H = H)$$

$$\text{즉, } (h_{i1} \quad \cdots \quad h_{in}) \begin{pmatrix} h_{1i} \\ \vdots \\ h_{ni} \end{pmatrix} = \sum_{j=1}^n h_{ij}^2 = h_{ii}$$

7. $\frac{1}{\hat{\sigma}^2(p+1)} \sum_{j=1}^n (\hat{Y}_j - \hat{Y}_{j(i)})^2$

$$= \frac{r_i^2}{p+1} \cdot \frac{h_{ii}}{1 - h_{ii}} \rightarrow C_i : \text{Cook's distance.}$$

- 영향력 분석 관련 용어: $\frac{h_{ii}}{1 - h_{ii}}$: potential (잠재력)

$$8. \hat{y}_j - \hat{y}_{j(i)} = \frac{h_{ij}}{1 - h_{ii}} \cdot e_i$$

9. $y_i - \hat{y}_{i(i)}$

$$= y_i - \hat{y}_i + \hat{y}_i - \hat{y}_{i(i)}$$

$$= e_i + \frac{h_{ii}}{1 - h_{ii}} e_i = \frac{e_i - h_{ii} e_i + h_{ii} e_i}{1 - h_{ii}} = \frac{1}{1 - h_{ii}} e_i$$

10. PRESS

$$= \underbrace{\sum_{i=1}^n (y_i - \hat{y}_{i(i)})^2}_{\text{Leave-one-out cross validation}} = \sum_{i=1}^n \left(\frac{e_i}{1 - h_{ii}} \right)^2 \quad ()$$

11. $y_j - \hat{y}_{j(i)}$

$$= y_j - \hat{y}_j + \hat{y}_j - \hat{y}_{j(i)} = e_j + \frac{h_{ij}}{1 - h_{ii}} e_i$$

12. $SSE_{(i)}$

$$= \sum_{j \neq i}^n (Y_j - \hat{Y}_{j(i)})^2 = \sum_{j \neq i}^n \left(e_j + \frac{h_{ij}}{1 - h_{ii}} e_i \right)^2$$

$$\bullet \sigma_{(i)}^2 = SSE_{(i)} / (n - p - 2)$$

관측치의 영향력(influence of an observation)

- 관측치의 영향력을 측정하기 위한 지표가 있음

1. DFFITS :

$$DFFITS_i = \frac{\hat{Y}_i - \hat{Y}_{i(i)}}{\sigma_{(i)} \sqrt{H_{ii}}}$$

2. Cook's distance :

$$D_i = \frac{\sum_{j=1}^n (\hat{Y}_j - \hat{Y}_{j(i)})^2}{(p+1) \hat{\sigma}^2}$$

3. DFBETAS :

$$DFBETAS_{j(i)} = \frac{\hat{\beta}_j - \hat{\beta}_{j(i)}}{\sqrt{\hat{\sigma}_{(i)}^2 (X^T X)^{-1}_{jj}}}$$

11. Diagnostics in multiple linear regression II

Leverage (레버리지)

- **정의:**
 - $\hat{y} = X\hat{\beta} = \underbrace{X(X'X)^{-1}X'}_H Y$
 - $\hat{y}_i = h_{i1}y_1 + h_{i2}y_2 + \dots + h_{ii}y_i + \dots + h_{in}y_n$
 - $h_{ii} = X_i'(X'X)^{-1}X_i$ (X_i 는 i 번째 row)
 - 의미: i 번째 관측치의 레버리지
- Properties of leverage (레버리지의 성질)
 1. $\frac{1}{n} \leq h_{ii} \leq 1$
 2. $-0.5 \leq h_{ij} \leq 0.5$
 3. $\text{tr}(H) = \sum_{i=1}^n h_{ii} = p + 1$
 - (for model $Y_i = \beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{pi} + \epsilon_i$)

Centered Observations

$$Y_i^* = Y_i - \bar{Y}, \quad X_{ij}^* = X_{ij} - \bar{X}_j, \\ \text{where } \bar{X}_j = \frac{1}{n} \sum_{i=1}^n X_{ij}, \quad \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$$

Model with Centered Observations

- **표현:**
 - $Y_i - \bar{Y} = \beta_1(X_{i1} - \bar{X}_1) + \dots + \beta_p(X_{ip} - \bar{X}_p) + \epsilon_i$
 - $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}_1 - \dots - \hat{\beta}_p \bar{X}_p$

계수 벡터 분리:

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_p \end{pmatrix} \Rightarrow \hat{\beta}_C = \begin{pmatrix} \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_p \end{pmatrix}$$

중심화된 LSE $\hat{\beta}_C$

$$\hat{\beta}_C = (X_C'X_C)^{-1}X_C'(Y - \bar{Y}1_n)$$

중심화된 설명 변수 행렬 X_C

$$X_C = \begin{pmatrix} X_{11} - \bar{X}_1 & \dots & X_{1p} - \bar{X}_p \\ \vdots & \ddots & \vdots \\ X_{n1} - \bar{X}_1 & \dots & X_{np} - \bar{X}_p \end{pmatrix}_{n \times p}$$

중심화된 행렬의 특성:

- $1_n'X_C^{(j)} = \sum_{i=1}^n (X_{ij} - \bar{X}_j) = 0$ (각 열 벡터의 합이 0이다.)

$\hat{Y}$ 와 $Y - \bar{Y}1_n$ 의 관계

$$\begin{aligned} \hat{Y} &= HY = X(X'X)^{-1}X'Y \\ Y - \bar{Y}1_n &(\text{중심화된 } Y \text{ 벡터}) \\ &= X_C\hat{\beta}_C = X_C(X_C'X_C)^{-1}X_C'Y \end{aligned}$$

Centered (중심화된) 데이터를 이용한 $\hat{Y}$ 표현

$$\begin{aligned} \hat{Y} &= \bar{Y}1_n + X_C(X_C'X_C)^{-1}X_C'Y \\ \bar{Y} &= \frac{1}{n} \sum_{i=1}^n Y_i = \frac{1}{n} 1_n'Y \end{aligned}$$

$\hat{Y}$ 전개 및 H 행렬 유도 (증)

$$\hat{Y} = \left(\frac{1}{n} 1_n 1_n' + X_C(X_C'X_C)^{-1}X_C' \right) Y$$

H 행렬 정의

$$\begin{aligned} \Rightarrow H &= X(X'X)^{-1}X' \\ &= \left(\frac{1}{n} \underbrace{1_n 1_n'}_{\frac{1}{n} \leq h_{ii} \leq 1} + \underbrace{X_C(X_C'X_C)^{-1}X_C'}_{H_C} \right) \\ &\quad \text{■ } H_C: \text{대칭행렬, idempotent} \end{aligned}$$

Hat Matrix H 의 성질 유도

$$H = \frac{1}{n} 1_n 1_n' + H_C$$

1. $h_{ii} \geq \frac{1}{n}$ 유도 (최소값)

- $h_{ii} = e_i' H e_i = e_i' \left(\frac{1}{n} 1_n 1_n' + H_C \right) e_i$
- $e_i : I_n$ 행렬의 i 번째 열 (basis vector)
- $h_{ii} = \frac{1}{n} (e_i' 1_n) (1_n' e_i) + e_i' H_C e_i$
- $h_{ii} = \frac{1}{n} \cdot 1 \cdot 1 + e_i' H_C e_i$
- $h_{ii} = \frac{1}{n} + e_i' H_C e_i$
 - H_C 는 양의 준정부호 행렬 (Positive Semidefinite Matrix)
 - $e_i' H_C e_i \geq 0$

$$\Rightarrow h_{ii} \geq \frac{1}{n}$$

2. $h_{ii} \leq 1$ 유도 (최대값)

- * H 는 멱등 행렬 (Idempotent)

12. interactions and qualitative variable

salary example (stratification)

- 매니저 여부, 학력수준 (고/대/석)을 2*3=6가지 케이스 중 각 E와 M의 조합에 따라 모델을 6개로 분리

Use qualitative variables (케이스마다 서로 다른 절편)

- 또는 6가지의 경우의 수를 dummy variable을 사용해 나타낼 수 있음
 - (각 관측치는 동분산 σ^2 을 가정)
 - $S_i = \beta_0 + \beta_1 X_i + \beta_2 E_{i2} + \beta_3 E_{i3} + \beta_4 M_i + \epsilon_i$
 - $E_{i2} = \begin{cases} 1 & \text{if } E_i = 2 \\ 0 & \text{otherwise.} \end{cases}, \quad E_{i3} = \begin{cases} 1 & \text{if } E_i = 3 \\ 0 & \text{otherwise.} \end{cases},$
 $M_i = \begin{cases} 1 & \text{if } M \\ 0 & \text{otherwise.} \end{cases}$
- 절편에 dummy var 추가 시 : 경우의 수가 3개라면, 하나를 디폴트 케이스, dummy var은 2개만 쓴다

Interactions (케이스마다 서로 다른 기울기)

$$S_i = \beta_0 + \beta_1 X_i + \beta_2 E_{i2} + \beta_3 E_{i3} + \beta_4 M_i + \beta_5 E_{i2} X_i + \beta_6 E_{i3} X_i + \epsilon_i$$

Connection to One-way ANOVA

- Regression with Dummy Variables $\approx$ One-way ANOVA**
 - 범주형 변수(X)만 있는 회귀분석은 One-way ANOVA와 수학적으로 동치.
- 가설 검정**
 - $H_0 : \beta_2 = \beta_3 = \dots = 0$ (모든 더미 계수가 0)
 - $\iff H_0 : \mu_1 = \mu_2 = \dots = \mu_k$ (모든 그룹 평균이 동일)
 - F-test (Partial F-test)를 사용하여 검정.
- Parameter Constraints (제약조건)**
 - 회귀식 추정을 위해 제약조건 필요 (Design Matrix가 Full Rank가 아님).
 - Baseline Constraint (Treatment Contrast):** 특정 그룹(Base)의 효과를 0으로 둠. (R 기본값)
 - Sum-to-zero Constraint:** 모든 그룹 효과의 합을 0으로 둠 ($\sum \tau_i = 0$).

14. Correlated Errors (Autocorrelation)

Definition & Consequences

- **가정 위반 (Assumption Violation):** 오차항들 간에 상관관계가 존재함. $Cov(\epsilon_i, \epsilon_j) \neq 0, \quad i \neq j$.
 - 주로 **시계열 데이터(Time Series Data)** 에서 발생.
- **OLS 추정량의 성질 변화:**
 - $\hat{\beta}$ 는 여전히 **Unbiased Estimator** (편향되지 않음).
 $E(\hat{\beta}) = \beta$.
 - 그러나 $\hat{\beta}$ 는 더 이상 **Efficient**하지 않음 (Not BLUE). 분산이 최소가 아님.
 - **표준 오차(Standard Error)의 왜곡:**
 - 일반적으로 MSE 가 σ^2 를 과소 추정하게 됨.
 - 결과적으로 t -통계량이 뽕튀기(Inflated)되어, 유의하지 않은 변수를 유의하다고 잘못 판단할 수 있음 (**Spurious Regression**).
 - hint : $Var(\hat{\beta})_{OLS} = \sigma^2(X'X)^{-1}$ 공식이 더 이상 성립하지 않고,
 $Var(\hat{\beta}) = \sigma^2(X'X)^{-1}X'VX(X'X)^{-1}$ 형태가 됨.

Detection: Durbin-Watson Test

- **1차 자기회귀 모형 (AR(1) Model):**
 - $\epsilon_t = \rho\epsilon_{t-1} + u_t, \quad u_t \sim i.i.d. N(0, \sigma_u^2), \quad |\rho| < 1$
- **가설 (Hypothesis):**
 - $H_0 : \rho = 0$ (상관관계 없음)
 - $H_1 : \rho \neq 0$ (보통 양의 상관관계 $\rho > 0$ 를 검정)
- **검정 통계량 (D-Statistic):**
 - $d = \frac{\sum_{t=2}^n (e_t - e_{t-1})^2}{\sum_{t=1}^n e_t^2} \approx 2(1 - \hat{\rho})$
 - e_t : OLS 잔차.

의사 결정 (Decision Rule):

- $0 \leq d \leq 4$.
- $d \approx 2 \implies \hat{\rho} \approx 0$ (자기상관 없음).
- $d \approx 0 \implies \hat{\rho} \approx 1$ (양의 상관관계).
- $d \approx 4 \implies \hat{\rho} \approx -1$ (음의 상관관계).
- **기각역 (d_L, d_U Table 사용):**
 - $d < d_L$: Reject H_0 (양의 상관 존재).
 - $d > d_U$: Do not Reject H_0 .
 - $d_L \leq d \leq d_U$: **Inconclusive** (판단 보류).

Remedial Measures (해결 방안)

- **Generalized Least Squares (GLS):**
 - 오차항의 공분산 구조(V)를 고려하여 변수를 변환한 후 OLS 수행.
- **변수 변환 (Transformation) 아이디어:**
 - 모델: $Y_t = \beta_0 + \beta_1 X_t + \epsilon_t$
 - $t-1$ 시점 모델에 ρ 곱함:
 $\rho Y_{t-1} = \rho\beta_0 + \rho\beta_1 X_{t-1} + \rho\epsilon_{t-1}$
 - 두 식을 뺌 (Difference):
 - $(Y_t - \rho Y_{t-1}) = \beta_0(1 - \rho) + \beta_1(X_t - \rho X_{t-1}) + \underbrace{(\epsilon_t - \rho\epsilon_{t-1})}_{=u_t}$
 - 변환된 변수
 $Y'_t = Y_t - \rho Y_{t-1}, X'_t = X_t - \rho X_{t-1}$
에 대해 OLS 수행.
 - u_t 는 백색 잡음(White Noise)이므로 OLS 가정 만족.
- **ρ 의 추정:**
 - 실제 ρ 를 모르므로 e_t 를 이용해 $\hat{\rho}$ 추정 (Cochrane-Orcutt Procedure 등 사용).
 - hint : 첫 번째 관측치($t=1$)를 잃어버리는 문제를 보정한 방법이 Prais-Winsten Estimation.

15. Model Selection

Outline(model selection)

- 회귀 상황에서 Y와 X가 centered 되었다 가정. :

$$Y_{(n \times 1)} = X_{(n \times p)}\beta_{(p \times 1)} + \epsilon_{(n \times 1)}$$
- 부분집합 $A \subset \{1, \dots, p\}$ 에 대해 새 회귀 모형 :

$$M(A) : Y_{(n \times 1)} = X[:, A]\beta[A] + \epsilon_{(n \times 1)}$$
 - $(\beta[A^c] = 0)$ 라 세팅; 총 가능한 모델선택은 2^p
 - 모델선택 $\rightarrow$ 1) 어떤 기준? 2) 어떻게 탐색?(p가 크면 전수조사 어렵)

Problem & Goals

- x_1, x_2, x_3 에 대해, $x_3 = [x_{31}, \dots, x_{39}]$; 가능한 모델 갯수=29
 - $x_1, x_2, x_{31}, \dots, x_{39} \rightarrow 11$ 개;
 - $x_1x_{31}, \dots, x_1x_{39} \rightarrow 9$ 개
 - $x_2x_{31}, \dots, x_2x_{39} \rightarrow 9$ 개
 - main effect(1) + interactions (2),(3)

Justifying parsimony

- Principle of parsimony(오컴의 면도날)
 - p개의 설명변수로 설명 O 모델보단 j(j < p)개의 설명변수로 설명 O 모델 best
- ex) (model 1) :

$$Y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \epsilon_i; \quad (\beta_2 = 0)$$
 - $Var(\hat{\beta}_1^{M1}) = \sigma^2((X'X)^{-1})_{11}$

$$= \frac{\sigma^2 S_{2,2}}{S_{1,1}S_{2,2} - S_{1,2}^2}$$

- hint : let $S_{a,b} = \sum_{i=1}^n x_{ia}x_{ib}$;
 $X, X'X, X'Y$ 행렬 정의, 역행렬 정의

- (model 2) : $Y_i = \beta_1 x_{i1} + \epsilon_i$; $Var(\hat{\beta}_1^{M2}) = \frac{\sigma^2}{S_{1,1}}$
 - $Var(\hat{\beta}_1^{M1})/Var(\hat{\beta}_1^{M2})$

$$= 1 + \frac{S_{1,2}^2}{S_{1,1}S_{2,2} - S_{1,2}^2} \geq 1$$
 - hint : 코시-슈바르츠 부등식 : $S_{1,1}S_{2,2} \geq S_{1,2}^2$

Candidate criteria

Candidate criteria

- R^2 : 좋은 평가 지표X; 단순히 파라미터 갯수가 늘어도 증가함
- $adj. R^2$: 더 나은 평가 지표; 과적합을 일부 방지;
- Mallow's C_p : 모델의 예측력을 평가함 (새 관측치에 대한 예측력)
- (실무) : AIC(예측), BIC(true model), Cross-validation 등 평가 지표

Mallow's C_p

- $C_p(M) = \frac{SSE(M)}{\hat{\sigma}^2} + 2p_M - n$ (p_M : # of params in Model)
 - $= \frac{S_A - \hat{\sigma}^2}{\hat{\sigma}^2/(n-p_M)} + p_M$
 if $S_A^2 \rightarrow \hat{\sigma}^2$, then $C_p(M(A)) \rightarrow p_M$
 - hint : let $S_A^2 = SSE(M(A))/(n - p_M)$; p_M : # of predictors in M

Search strategies

start	step 1	...	step p
$Y_i = \beta_0 + \epsilon_i$	$+X_1$		
	$\vdots$	$\Rightarrow$	1스텝에 1개씩 추가
(foward selection)	$+X_p$		개선X? stop

•

start	step 1	...	step p
$Y_i = \beta_0 + \sum_{j=1}^p \beta_j X_{ij} + \epsilon_i$	$-X_1$		
	$\vdots$	$\Rightarrow$	1스텝에 1개씩 추가
(backward selection)	$-X_p$		개선X? stop

•

•

•

start	step 1	step 2	...	step p
	ex) foward	ex) X_1 choice		
(foward or backward)	$+X_1$	$+X_2$		
	$+X_2$	$\vdots$	$\Rightarrow$	for, back 둘 중 하나 따름
	$\vdots$	$+X_p$		다음 스텝에 이전 걸 뺄지 결정
(stepwise selection)	$+X_p$	(선택 : $-X_1$)		

- 계산비용 : 총 p개의 step중 step j에서 p-j+1개의 모형 적합

◦ (모형의 수)

$$= \sum_{j=1}^p p - j + 1 = \sum_{j=1}^p j = p(p+1)/2$$

16. Penalized Regression

Penalized Regression Concepts (Collinearity, Ridge, Lasso)

Bias-Variance Trade-off

개념 및 목적

- **목표:** $MSE(\hat{\beta})$ (Mean Squared Error)의 최소화.
 - MSE 관점에서는 Unbiased Estimator가 항상 최적은 아님.
 - Bias(편향)가 약간 생기더라도 Variance가 급격히 줄어든다면 전체 MSE 감소 가능.

Decompositon (분해 유도)

- **Goal:**
$$MSE(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = Var(\hat{\theta}) + [Bias(\hat{\theta})]^2$$

증명

 - $E[(\hat{\theta} - \theta)^2] = E[(\hat{\theta} - E(\hat{\theta}) + E(\hat{\theta}) - \theta)^2]$
 - $= E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2 + 2(E(\hat{\theta}) - \theta) \underbrace{E[\hat{\theta} - E(\hat{\theta})]}_{=0}$
 - $= Var(\hat{\theta}) + [Bias(\hat{\theta})]^2$
 - hint : $A + B$ 의 완전제곱식 $(A + B)^2 = A^2 + B^2 + 2AB$ 활용.

- hint : $E(\hat{\theta}) - \theta$ 는 상수(Constant) 취급하여 기댓값 밖으로 나눔.

Multicollinearity (다중공선성)

Definition (정의)

- 설명 변수(X)들 간에 강한 선형 상관관계가 존재하는 경우.
- **증상 (Variance Inflation):**
 - 회귀 계수 $\hat{\beta}$ 의 **Variance(분산) 폭발**.
 - 수식적 원인: $Var(\hat{\beta}) = \sigma^2(X^T X)^{-1}$
 - $X^T X$ 의 eigenvalue $\approx 0 \implies$ 역행렬의 eigenvalue $\rightarrow \infty$.
 - hint : $(X^T X)^{-1}$ 는 $X^T X$ 의 고유값의 역수 $(1/\lambda_i)$ 를 고유값으로 가짐. $\lambda_{min} \rightarrow 0$ 이면 $Var \rightarrow \infty$.

Diagnostics (진단)

- **VIF (Variance Inflation Factor):**
 - $VIF_j = \frac{1}{1-R_j^2}$
 - R_j^2 : X_j 를 종속변수로, 나머지 X 들을 설명변수로 했을 때의 결정계수.
 - **유도 의미:** X_j 가 다른 변수들로 설명이 잘 될수록 $R_j^2 \rightarrow 1$, 분모가 0에 가까워져 VIF 급등.
 - **기준:** $VIF > 10$ 이면 심각.