

금융계량 중간대비(lect. 1~5)

1. OLS review

OLS as minimizing residuals

회귀식 $y_i = \beta_0 + \beta_1 x_i + e_i$

- $(x_1, \dots, x_n), (y_1, \dots, y_n)$ 의 n개의 관측치를 고려.
- OLS : 데이터를 가장 잘 설명하는 선($\hat{\beta}_0 + \hat{\beta}_1 x$)을 찾아냄. 추정치.
 - $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ 는 y_i 에 대해 추정/예측된 값.
 - $\hat{u}_i = y_i - \hat{y}_i$ 는 잔차; 모델로 설명/예측 X인 값

SSE(Squared Sum of Errors)와 OLS

- OLS는 잔차 최소화할 β_0, β_1 찾. $\hat{u}_i^2$ 최소화 되게(미-가 고려)
- 목표 : $\operatorname{argmin} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$
 - $\hat{\beta}_1^* = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{\operatorname{Cov}(x, y)}{\operatorname{var}(x)}, \hat{\beta}_0^* = \bar{y} - \hat{\beta}_1^* \bar{x}$

Regression model and classical assumptions

다중회귀 식 $y_i = \beta_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki} + e_i$ 가 주어질 때,

- 선형성(Linearity): 변수들간 선형적 관계.
- 조건부 기댓값 0: $E[e_i | X_{1i}, \dots, X_{ki}] = 0 \quad \forall i$.
 - 위배 : $E[e_i | X] \neq 0 \rightarrow$ OLS X. biased estimator가 됨.
 - 언제 위배되나?
 $y_i = \beta_0 + \dots + \beta_k x_{ki} + (\beta_{k+1} x_{k+1i}) + e_i$ 라고
 없음
 잘못 추정.
 - $e_i = e_i^T + \beta_{k+1} x_{(k+1)i}$ 의 참모델의 정보 포함.
 - $x_{1i}, x_{(k+1)i}$ 간 공선성 높?
 $\hat{\beta}_1 \rightarrow \beta_1 + \beta_{k+1} \frac{\Delta x_{(k+1)i}}{\Delta x_{1i}}$ 로 편향; 다른 $\hat{\beta}$ 들도 편향.
 - 해결책 : 빠진 변수를 넣; 도구변수, 2SLS 사용
- 동분산성(Homoskedasticity):
 $E[e_i^2 | X_{1i}, \dots, X_{ki}] = \sigma^2 \quad \forall i$
- 독립성 : $\operatorname{Cov}[e_i e_j] = E[e_i e_j] = 0 \quad \forall i \neq j$
 - 3. or 4. 위배시(이분산성/변수간 상관) : OLS는 BLUE가 X.
 - 해결책 : GLS 사용; Feasible GLS : 오차의 이분산성/상관성을 추정
- 다중공선성 부재: x간 완전한 선형관계 X (no perfect multi-collinearity)
 - 위배 : 완전 다중공선성 $\rightarrow$ OLS 작동 X / 약 다공성 $\rightarrow$ 왜곡된 추정치
- 정규성: $e_i \sim N(\cdot)$

- 위배 : 정확한 통계적 추정 대신 근사만 O; 샘플 크기 n이 충분히 크면 OK

가우스-마르코프 정리, BLUE

- 가우스-마르코프 정리 : 위 6가지 가정 성립시, OLS는 Best Linear Unbiased Estimator.

2. Return Predictability I

Unconditional and conditional expectation

- Unconditional : $E(Y) = \int y \cdot p(y) dy$
- Conditional : $E(Y | X = x) = \int y \cdot p(y | X = x) dy$

Law of iterative expectation

- 반복 기대의 법칙 : $E(Y) = E(E(Y | X))$
 - 조건부 확률들의 평균은 무조건부 확률과 같다

Shiller의 합리적 기대 위배 사례



- 주식시장의 초과 변동성(Excess Volatility): 주가의 펀더멘털인 배당금보다 훨씬 요동침
 - 합리적 기대 가설 : 경제주체들은 모든 정보를 통해 미래를 합리적으로 예측
 - 합기 내에서 주가는 미래 배당금들을 현재가치로 할인한 합으로 결정 $\rightarrow$ 따라서 주가는 배당금에 동기화.
 - but, 실러는 실제 주가 변동성이 훨씬 $\uparrow$, 가설에 위배됨을 보임.
 - (그래프; 배당(녹)보다 주가(빨)이 훨씬 변동성 $\uparrow$; 수익(파), 이자율(검))
- 수익률 예측에 대한 전통적 관점 : 합기에 따라 초과 예측/수익은 있을 수 X; 가격은 배당에 대한 충격(news/shock)에 의존
- 직관 : 배당은 비교적 천천히 움직이는데 가격은 훨씬 크게 흔들리므로, 가격에는 배당 말고도 기대수익률/할인율에 대한 정보가 들어 있다고 본다.
- 예시 : 같은 기업인데 배당 전망 변화는 크지 않아도 금융 위기 때 주가가 급락하는 것은 할인율(요구수익률) $\uparrow$ 때문

Traditional view for return predictability

- $R_{t+1} = a + bx_t + \epsilon_{t+1}$
 - $b = 0$ 라면, $E_t[R_{t+1}] = a$; 수익을 예측할 수 X.
 - $\therefore$ 무조건부 평균인 a 이상으로 예측할 수 X.
 - $\rightarrow$ 예측 X = 현재 시장에 모든 정보 반영.
 - $b \neq 0$ 라면, $E_t[R_{t+1}] = a + bx_t$; 수익을 예측할 수 있다

	$R_{t+1} = a + bR_t + \epsilon_{t+1}$				
	b	t(b)	R ²	E(R)	$\sigma(E_t(R_{t+1}))$
Stock	0.04	0.33	0.002	11.4	0.77
T bill	0.91	19.5	0.83	4.1	3.12
Excess	0.04	0.39	0.00	7.25	0.91

	t(b)	R ²	$\sigma(\cdot)$
주식	↓	↓	↓
국채	↑	↑	↑
초과수익	↓	↓	↓

- (초과수익 : $R_{t+1} - \text{T-bill, Risk free rate}$)


Dividend-price ratio

- $R_{t+1} = \frac{P_{t+1} + D_{t+1}}{P_t}$: 미래 수익 = 미래의 가격&배당과 비례, 현재 가격과 반비례
- $P_t = \frac{P_{t+1} + D_{t+1}}{R_{t+1}}$: 현재 가격 = 미래의 현금흐름(주가 + 배당)에 대한 현재가치(수익률)
 - $P_t = \sum_{j=1}^{\infty} \frac{D_{t+j}}{\prod_{i=1}^j R_{t+i}} = E_t P_t$
 - $E_t D_{t+1}$ 가 바뀔때 : $E_t D_{t+1} \uparrow \rightarrow P_t \uparrow$
 - $E_t R_{t+1} \uparrow \rightarrow P_t \downarrow$; 리스크 $\uparrow \rightarrow$ 리턴 $\uparrow$
- 직관 : 현재 가격은 미래 현금흐름을 할인한 값이므로, 가격이 낮아지면 같은 배당 대비 D/P는 올라간다.
- 예시 : 경기 불안으로 투자자들이 더 높은 수익률을 요구하면 가격은 내려가고 D/P는 올라간다.
- D/P ratio에 대한 로그 차분
 - OLS가 불가능. 데이터를 변환
 - $R_{t+1} = \frac{D_{t+1}}{P_t} \rightarrow \frac{D_{t+1}}{D_t} = \frac{E_t(D_{t+1}/D_t)}{E_t(R_{t+1})}$
 - hint: $E_t(\cdot)$ 씌우고 $P_t, E_t(R_{t+1})$ 자리 바꿈, D_t 나눔
 - (1기 동안만 hold한다 가정)
 - $p_t - d_t = E_t(\Delta d_{t+1}) - E_t(r_{t+1})$ (위에 로그)
 - 의미 :
 - 투자자들이 미래 배당/수익에 대한 정보를 얻어 기대를 형성, 현재 가격이 반영
 - $\Delta d_{t+1}, r_{t+1} \rightarrow E_t(\Delta d_{t+1}), E_t(r_{t+1}) \propto p_t$
 - 투자자들의 정보 모르지만, 기대가 현재에 반영 ($p_t - d_t$)
 - D/P? : {현재 가격(P_t) $\uparrow$ + 할인률 기대수익률($E(R_{t+1}))$ $\downarrow$ }의 신호
 - p_t 에 영향 주는것?

- dividend growth ($E_t(\Delta d_{t+1}) \uparrow$) : 회사 성장 기류; $p_t \uparrow$
- discount rate ($E(r_{t+1}) \uparrow$) : risk $\uparrow$; $p_t \downarrow$

- 직관 : D/P가 높다는 것은 보통 “배당이 갑자기 좋아졌다”기보다 “현재 가격이 낮거나 기대수익률이 높다”는 쪽으로 해석한다.


New view for return predictability



- ◦ 배당(파)과 7년후 수익(빨)이 대략적으로 들어맞음
- 경제주체는 모든 정보를 사용, but, 연구자는 일부 정보만 OK. 나머지는 예측오차

Horizon k (years)	$R_{t \rightarrow t+k}^e = a + b \frac{D_t}{P_t} + \varepsilon_{t+k}$	$\frac{D_{t+k}}{D_t} = a + b \frac{D_t}{P_t} + \varepsilon_{t+k}$				
	b	$t(b)$	R^2	b	$t(b)$	R^2
1	4.0	2.7	0.08	0.07	0.06	0.0001
2	7.9	3.0	0.12	-0.42	-0.22	0.001
3	12.6	3.0	0.20	0.16	0.13	0.0001
5	20.6	2.6	0.22	2.42	1.11	0.02

- ◦ $R_{t \rightarrow t+k}^e$: $t \rightarrow t+k$ 기간의 초과 수익; $\frac{D_t}{P_t}$: Proxy변수
 - 초과 수익 $\rightarrow$ 예측 O; D/P는 미래 수익의 충격을 반영, 기대는 예측력 O
 - 배당 성장 $\rightarrow$ 예측 X; D/P는 미래 배당 성장에 대한 충격 반영 X



- old view vs new view 정리
 - old : 가격 $\rightarrow$ 모든 정보 고려 $\rightarrow$ 오늘의 정보를 다 써서 주가로 사용; 정보 X, 가격 그대로, 그럼 배당도 가격에 맞춰 조정
 - new : $E_t(R_t)$ 가 조정됨에 따라 예측 O 부분 O.
 - 배당 $\rightarrow$ 회사의 모든 정보 반영
 - 가격 $\rightarrow$ 가격하락(저평가), $\therefore$ 리스크; $\rightarrow$ 즉, 미래의 $E_t R_{t+1} \uparrow$, 가격은 미래에 $\uparrow$


- 직관 : new view의 핵심은 D/P가 미래 배당성장보다 미래 기대수익률의 변화를 더 잘 담는다는 것이다.
- 예시 : D/P가 높은 시기에는 “배당이 폭증할 것”이라기보다 “위험이 커서 앞으로 더 높은 수익률을 요구한다”

3. Basic Time Series

Differences Between Cross-sectional and Time series data

- 1. 보통 과거->최근 정렬 2. 현실적으로 랜덤샘플링 가정 X
- 3. 시간에 따라 데이터간 강력한 상관성 4. 강 상관성 -> OLS X
- 5. 다수가 trend를 보이는 경향 6. seasonality 관찰 가능
 - ∴ 관측치간 시간적으로 강하게 연결 -> CS Data 쓰듯 OLS X. stationary함을 보장해야함
- 직관 : 시계열은 오늘 값이 어제 값과 연결되어 있어, 관측치 하나하나가 서로 독립이라고 보기 어렵다.
- 예시 : 오늘의 금리와 어제의 금리는 거의 연결되어 있지만, 두 사람의 키처럼 서로 독립표본으로 보기 어렵다.

Stationary



- 핵심 아이디어 : $E()$, $Var()$, $Cov()$ 가 시간에 따라 똑같다. 일정함
- 확변의 모멘트 : $E[Y^k]$: k번째 모멘, $E[(Y - E[Y])^k]$: k번째 중앙모멘트
 - 데이터 분포 파악을 위한 통계값들
 - 1st/2nd/3rd/4th moment : 평균,기댓값/분산,공분산/왜도/첨도
- 약한 stationary 프로세스
 - $E(Y_t) = \mu, \forall t$
 - $var(Y_t) = \sigma^2, \forall t$
 - $cov(Y_t, Y_{t-j}) = \gamma_j, \forall t$
- 직관 : stationary의 핵심은 데이터가 출렁이더라도 “출렁이는 규칙” 자체는 시간에 따라 바뀌지 않는 것이다.
- 예시 : 평균 2%, 분산도 비슷한 범위에서 움직이는 인플레이션은 stationary에 가깝고, 계속 우상향하는 GDP level은 보통 non-stationary다.
- Stochastic process vs Time series data
 - Stochastic : a sequence of random variable ordered in time(Ex-ante)
 - Time series : A particular realization of stochastic process(Ex-post)

FDL(Finite Distributed Lag) Models

- 정의 : 오늘 z 의 변화가 q 기에 걸쳐 y 에 영향을 미침 : FDL of order q
 - ex) 면세(pe)로 인한 2년간 출생률(gfr)변화 : $gfr_t = \alpha_0 + \delta_0 pe_t + \delta_1 pe_{t-1} + \delta_2 pe_{t-2} + u_t$
- FDL model of order q : $y_t = \alpha_0 + \delta_0 z_t + \dots + \delta_q z_{t-q} + u_t$
 - Impact propensity(IP, 즉각 효과) = δ_0 : 현재의 충격을 capture
 - Long run propensity(LRP, 장기 효과) = $\delta_0 + \dots + \delta_q$: 충격 -> 모든 기간의 효과 capture
- 직관 : 어떤 정책이나 충격은 오늘 바로 끝나지 않고 몇기에 걸쳐 천천히 반응할 수 있으므로 시차항을 같이 넣는다.
- 예시 : 금리 인상은 같은 분기 소비를 바로 다 바꾸기보다, 몇 분기 뒤 투자와 소비를 누적적으로 줄일 수 있다.
- 테일러 준칙 : $ffrate_t = \alpha_0 + \delta_0 inf_t + \dots + \gamma_0 gdpgap_t + \dots + u_t$
 - (ffrate : 기준금리, $gdpgap = |(\text{잠재 GDP}) - (\text{실질 GDP})|$)
 - Q : 이 모델에 자기자신을 추가하면?($ffrate_{t-1}$ 등) -> Lagged Dependent Variables

Models with Lagged Dependent Variables

- $y_t = \alpha_0 + \beta_0 y_{t-1} + u_t$ < AR(1)
 - 가정 : $y_t \rightarrow$ stationary; $u_t \rightarrow$ 모델의 설명력이 충분, 트렌드/패턴 X($u_t \sim N(0, \sigma^2)$)
 - 테일러 준칙에 적용 : $i_t \rightarrow \pi_t$ (오늘 이자율변화 -> 오늘 인플레이 변화?)
 - 정책시차의 필요 : $inf_t = \beta_0 + \beta_1 inf_{t-1} + \beta_2 unem_{t-1} + u_t = E(inf_t | I_{t-1}), E(u_t | I_{t-1}) = 0$
 - $E(inf_{t+1} | I_t) = \beta_0 + \beta_1 + inf_t + \beta_2 unem_t + 0$ ($\because E()$)
 - 예측오차 : $\eta_{t+1} = \pi_{t+1} - E(\pi_{t+1} | I_t)$

Characterizing Trending Data

- seasonality가 있는 y_t 를 어떻게 stationary하게 바꿔 OLS O?? : $y_t \rightarrow \Delta y_t$
 - $y_t = \alpha_0 + \alpha_1 t + e_t, E(y_t) = \alpha_0 + \alpha_1 t \rightarrow$ mean이 constant가 X
 - $\Delta y_t = y_t - y_{t-1} = \alpha_1 + \Delta e_t, E(\Delta y_t) = \alpha_1, \forall t$
- 직관 : 추세가 있으면 수준(level)을 그대로 비교하기보다 변화량(change)을 보는 편이 더 안정적이다.
- 예시 : 물가 수준은 계속 오를 수 있어도 물가상승률은 상대적으로 안정적일 수 있으므로, level보다 차분이나 로그차분을 본다.

- 자기 자신의 과거가 포함된 경우(exponential trend <- ??)
 - $y_t = \exp(\beta_0 + \beta_1 t + e_t) \rightarrow \ln(y_t) = \beta_0 + \dots$
 $\rightarrow \Delta \ln(y_t) = \beta_1 \approx \frac{y_t - y_{t-1}}{y_{t-1}}$
- ARMA 소개
 - $\frac{\partial Y_{t+j}}{\partial e_t}$: 오늘의 한단위 충격이 미래에 어떻게 영향?
 - let, y_t : stationary, $\rightarrow$ 모든 stationary $\rightarrow$

$$\underbrace{\psi_0 e_0}_{\text{상수, deterministic}} + \underbrace{\sum_{i=1}^{\infty} \psi_i e_i}_{\text{stochastic}}$$

Using Trending Data in Regression Analysis

- 회귀식에 t를 넣으면 Time trend가 잡힘; X? $\rightarrow \beta_1, \beta_2$ 추정에 심각한 편향
- $y_t = \beta_0 + \beta_1 x_{t1} + \beta_2 x_{t2} + \beta_3 t + u_t \quad t \in [1, n]$

Finite-sample Analysis of OLS for Time Series Data

- stationary의 조건 만족?
 1. linear params
 2. No perfect corlinearity
 - 설명력 너무 ↑ X, 식별에 문제 $\rightarrow var \uparrow \uparrow \rightarrow$ 가설 검정 hard, 1종/2종 오류 O
 3. 0 conditional mean : $E(u_t | \mathbb{X}) \rightarrow$ (엄격한 외생성); 모든 시점에 대해 공선성 X
 - 깨지면? $\rightarrow$ 내생성 문제; $if \neq 0 \implies$ biased, 내생성 O
 - 어떻게 해결? $\rightarrow$ consistant estimating($if n \rightarrow \infty, then bias \xrightarrow{p} 0$)
- 테일러 준칙에서의 0 conditional mean 예시
 - $\pi_t = \alpha_0 + \delta_0 r_t + \delta_1 r_{t-1} + \delta_2 r_{t-2} + u_t$
 - 엄외가 성립? $\rightarrow$ 오늘의 오차가 과거-현재-미래의 금리와 무관,
 - but, 설명 X인 외부 충격 개입(전쟁 등) $\rightarrow |u_t| \uparrow \uparrow$
 - $u_t > 0$ 면 중앙은행이 $r \uparrow \uparrow \rightarrow \pi \uparrow \uparrow$
 - $\therefore$ 오차-독립변수간 상관관계 O, 엄격한 외생성 X; 현실에선 위배 easy
- Asymptotics(점근적 성질) & Contemporaneous Exogeneity(동시대적 외생성)
 - 가정 : $cov(x_{ti}, x_{tj}) = 0, \forall i \neq j \rightarrow E(x_t u_t) = 0$ 즉, 동기간의 독립변수간 상관관계 X면 OK
 - 만족시 consistent variable. 유한 샘플 $\rightarrow$ OLS X(내생성), 무한 샘플 $\rightarrow$ OLS O(동기간 외생성)
 - strict exogeneity보단 약한 가정

- $\hat{\beta} = \beta + \frac{\sum_{t=1}^T x_t y_t}{\sum_{t=1}^T x_t' x_t} = (X'X)^{-1} X'Y$
 $(X : (n \times k), Y : (T \times 1))$
- 목표 : if $n \rightarrow \infty$, then $\hat{\beta} \xrightarrow{p} \beta$? (즉, $E(\hat{\beta}) = \beta$?)
 1. $\frac{1}{n} \sum_{t=1}^T x_t' x_t \xrightarrow{p} R \in \mathbb{R}$
 2. $\frac{1}{n} \sum_{t=1}^T x_t y_t \xrightarrow{p} 0$
 - law of iterative expectation : if $E(u_t | X_t) = 0$, then $E(u_t X_t) = E(E(u_t X_t | X_t)) = E(X_t \cdot \underbrace{E(u_t | X_t)}) = 0$
 - 경제학적 의미 : 같은 기간의 shock가 내 독립 변수와 상관성이 없다. (war $\uparrow \rightarrow r \uparrow$ X)
 - 만일 현 모델 x중 u와 관련 있? $\rightarrow$ 그 feature를 뺌

4. ARMA

Motivation

- Auto Regressive Moving Average(ARMA) : 가장 단순한 선형 단변량 시계열 모델
 - 현재 한단위 충격이 미래에 영향을 얼마나 주는지 ($\frac{\partial Y_{t+i}}{\partial e_t}$)
 - $Y_t = \psi_0 e_0 + \underbrace{\psi_1 e_1 + \dots}_{\text{wold form(representation)}}$
- 직관 : ARMA는 “현재 값 $\rightarrow$ 과거 상태를 얼마나 기억? (AR)”와 “과거 충격의 흔적이 얼마나 남는가(MA)”
- 예시 : (주식수익률)충격이 짧 : MA, 인플레이션 관성률 : AR 이 더 직관적.

ARMA(p,q)


$$Y_t = \mu + \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q} \quad \epsilon_t \sim N(0, \sigma^2)$$

- ◦ mead-adj. 형태 : $Y_t - \mu$ 꼴을 사용
- AR : (과거 나) -영향 $\rightarrow$ (현재 나) (영향 감; p기간 동안) 즉, 충격 오래
- MA : (과거 충격) -영향 $\rightarrow$ (현재 나) (영향 짧; q기간) 충격 짧
- any stationary time series $\rightarrow$ wold form
 - 오차 $\rightarrow$ 실제 데이터엔 없음

MA Model

- 모든 sta. time series $\rightarrow$ wold form
 - but, 오차 $\rightarrow$ 실제 Data엔 X.

ACF(AutoCorrelation Function)



Properties of MA(1)

- MA(1) :

$$Y_t = \mu + \epsilon_t + \theta\epsilon_{t-1} \quad \theta \in \mathbb{R}, \epsilon_t \stackrel{iid}{\sim} N(0, \sigma_\epsilon^2)$$
 - 충격 $\rightarrow$ 짧(θ에 달림)
- 직관 : MA는 “상태가 기억하는 것”이 아니라 “한 번의 충격이 몇 기 동안 잔향을 남기나”를 보는 모형이다.**
- $E[Y_t] = \mu + E[\epsilon_t] + \theta E[\epsilon_{t-1}] = \mu$
- $Var[Y_t] = \sigma^2 = E[(Y_t - \mu)^2] = \sigma_\epsilon^2(1 + \theta^2)$
- $Cov[Y_t, Y_{t-1}] = \gamma_1 = E[(Y_t - \mu)(Y_{t-1} - \mu)] = \theta\sigma_\epsilon^2$
 - $Cov[Y_t, Y_{t-2}] = \gamma_2 = 0$
 - $Cov[Y_t, Y_{t-j}] = \gamma_j; \quad \forall j > 1$
- $\rho_1 = \frac{\gamma_1}{\sigma^2} = \frac{\theta}{(1+\theta^2)}, \quad \rho_j = \frac{\gamma_j}{\sigma^2} = 0; \quad \forall j > 1$
 - $\theta(=, >, <)0 \rightarrow \rho_1(=, >, <)0$
- Dynamic Stability Condition : $\lim_{j \rightarrow \infty} \rho_j = 0$
 - ex) 반응X or ↓↓ : 충격 내재화, 통화정책 $\rightarrow$ 유동성 합정

Properties of MA(2)

- MA(2) :

$$Y_t = \mu + \epsilon_t + \theta_1\epsilon_{t-1} + \theta_2\epsilon_{t-2} \quad \theta \in \mathbb{R}, \epsilon_t \stackrel{iid}{\sim} N(0, \sigma_\epsilon^2), \forall t$$
 - $E[Y_t] = \mu + E[\epsilon_t] + \theta_1 E[\epsilon_{t-1}] + \theta_2 E[\epsilon_{t-2}] = \mu$
 - $Var[Y_t] = \sigma^2 = E[(Y_t - \mu)^2] = \sigma_\epsilon^2(1 + \theta_1^2 + \theta_2^2)$
 - $Cov[Y_t, Y_{t-1}] = \gamma_1 = \theta_1\sigma_\epsilon^2$
 - $Cov[Y_t, Y_{t-2}] = \gamma_2 = \theta_2\sigma_\epsilon^2$
 - $Cov[Y_t, Y_{t-j}] = \gamma_j; \quad \forall j > 2$
 - $\rho_{1,2} = \frac{\gamma_{1,2}}{\sigma^2} = \frac{\theta_{1,2}}{(1+\theta_1^2+\theta_2^2)}, \quad \rho_j = \frac{\gamma_j}{\sigma^2} = 0; \quad \forall j > 2$
 - DSC : $\lim_{j \rightarrow \infty} \rho_j = 0$

AR Model

Properties of AR(1)

- AR(1) :

$$Y_t = c + \phi Y_{t-1} + \epsilon; \quad \phi \in (-1, 1), \epsilon_t \stackrel{iid}{\sim} N(0, \sigma_\epsilon^2)$$
 - $E[Y_t] = \frac{c}{1-\phi} = \mu$
 - $\gamma_0 = Var(Y_t) = \frac{\sigma_\epsilon^2}{1-\phi^2}$ (by sta. 가정)
 - $\gamma_j = Cov(Y_t, Y_{t-j}) = \phi^j \frac{\sigma_\epsilon^2}{1-\phi^2}$ (by stat.)
 - $\rho_j = \frac{\gamma_j}{\gamma_0} = \phi^j$
 - DSC : $\lim_{j \rightarrow \infty} \rho_j = 0$
 - AR(1)이 DSC를 항상 만족? $\rightarrow$ 현실에선 $|\phi| < 1$ X일수도.
 - $\therefore H_0 : \phi = 1$ 을 검정후 기각. (unit root test)
- 직관 : AR(1)은 오늘 상태가 내일로 얼마나 이어지는지를 보는 가장 단순한 persistence 모형이다.**
- 예시 : 인플레이션의 ϕ 가 크면 오늘의 물가상승 충격이 다음 분기에도 오래 남는다는 뜻이다.**

Properties of AR(2)

- AR(2) :

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \epsilon_t \quad \epsilon_t \sim iid N(0, \sigma_\epsilon^2)$$
 - mean : $E[Y_t] = \frac{c}{1-\phi_1-\phi_2} = \mu$
 - Var : 구하기 위해 행렬 (stationary 가정 $\rightarrow$ 일정함 가정)
 - 목표 : 고차원 AR(p)를 AR(1)로 바꿔 분산 봄. (1,1)원소 보면 발산 O? X?)
 - $$\begin{bmatrix} Y_t \\ Y_{t-1} \end{bmatrix} = \begin{bmatrix} \phi_1 & \phi_2 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} Y_{t-1} \\ Y_{t-2} \end{bmatrix} + \begin{bmatrix} \epsilon_t \\ 0 \end{bmatrix}$$

$$\Rightarrow \zeta_t^{(2 \times 1)} = F^{(2 \times 2)} \zeta_{t-1} + v_t^{(2 \times 1)}$$

$$v_t \sim N(0, R); \quad R = \begin{bmatrix} \sigma_\epsilon^2 & 0 \\ 0 & 0 \end{bmatrix}$$
 - $Var[\zeta_t] = F \cdot Var[\zeta_t] \cdot F' + Var[v_t]$

$$\Rightarrow Vec(Var[\zeta_t]) = (I_4 - F \otimes F)^{-1} Vec(R)$$
 - $Vec(Var[\zeta_t])_1 = Var(Y_t)$
 - hint : $Vec()$: 행렬을 벡터화; $\otimes$: 크로네커 곱. 분산 구조 정리
 - 핵심 : AR(p) 의 var/cov도 행렬로 연산 O
 - 해석 : 상백 전체보단 첫 원소 y_t
 - Stationary 테스트 : $\lim_{j \rightarrow \infty} \rho_j = 0$ 을 검증
 - $$\underbrace{\begin{bmatrix} \rho_j \\ \rho_{j-1} \end{bmatrix}}_{\rho_j} = \underbrace{\begin{bmatrix} \phi_1 & \phi_2 \\ 1 & 0 \end{bmatrix}}_F \underbrace{\begin{bmatrix} \rho_{j-1} \\ \rho_{j-2} \end{bmatrix}}_{\rho_{j-1}} \quad (\rho_j : \text{state vector, 내 상태를 정의})$$
 - F의 고유값 λ 에 대해 $F = T \Lambda T^{-1}, T^{-1} = T'$
 - $\lim_{j \rightarrow \infty} F^j = T \lim_{j \rightarrow \infty} \Lambda^j T^{-1} = 0$

$$\therefore |\lambda_n| < 1$$
 - 따라서 $|\lambda| < 1$ 이어야 sta. OK

Impulse response function

- $$\begin{bmatrix} Y_t \\ Y_{t-1} \\ \epsilon_t \\ \epsilon_{t-1} \end{bmatrix} = \begin{bmatrix} \phi_1 & \phi_2 & \theta_1 & \theta_2 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} Y_{t-1} \\ Y_{t-2} \\ \epsilon_{t-1} \\ \epsilon_{t-2} \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \\ 1 \\ 0 \end{bmatrix} \epsilon_t$$
- $\Rightarrow \zeta_t = F\zeta_{t-1} + v_t \quad v_t = R\epsilon_t$
- $\zeta_{t+j} = F\zeta_{t+j-1} + v_{t+j} \rightarrow F^{j+1}\zeta_{t-1} + \sum_{i=0}^j F^i(v_{t+j-i} = R\epsilon_{t+j-i})$
 - 다음 ζ 를 계속 대입하는 방식
 - $\therefore Y_{t+j} = (\zeta_{t+j})_1 = (F^j\zeta_{t+1})_1 + (\sum_{i=0}^j F^i R\epsilon_{t+j-i})_1$
 - $E[Y_{t+j}|I_t] = (F^j E[\zeta_{t+1}|I_t])_1$
 - $Var[Y_{t+j}|I_t] = (Var[\sum_{i=0}^j F^i R\epsilon_{t+j-i}])_1$
 - $\frac{\partial Y_{t+j}}{\partial \epsilon_t} = F^j R$
- 예제 : AR(2) : $Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \epsilon_t$ 모형에서 4기 후 GDP?

 - A : 식을 바탕으로 state vector 정리후
 - $\Rightarrow \zeta_t = F\zeta_{t-1} + v_t \quad v_t = R\epsilon_t$ 꼴로 변환후 F_{11} 를 찾는다
- ARMA에서 ϵ 은 보이지 X. 어떻게 활용? -> 칼만필터로 ok

 - 가장 잘 추정하는 방법 -> MLE; 오차항 X? OLS OK(오차항 없을때만).

IR 정리

AR(1) : $y_t = \phi y_{t-1} + e_t \quad (let, \mu = 0)$

- $\lim_{j \rightarrow \infty} \rho_j = 0$ 가정 $\Rightarrow$ stationary OK
- $\frac{\partial Y_{t+j}}{\partial e_t} = \phi^j, \phi = \lambda \quad |\phi| < 1 \rightarrow$ (stationary) 항상 X. (sta. 한 환경에서만)
 - $\phi(> / = / <) 1 \rightarrow$ (per. & 충격 증폭, 발산/per. 증폭 X/tran. 충격 소멸)

AR(2) : $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + e_t \quad (let, \mu = 0)$

- 가장 큰 계수가 sta. 을 결정
- 1st step : sta. space form 정의 -> 1st order model로 변형 (단, 고유하진 X)

 - $let \ z_t = Fz_{t-1} + \epsilon_t$

$$\Rightarrow \begin{pmatrix} y_t \\ y_{t-1} \end{pmatrix} = \begin{pmatrix} \phi_1 & \phi_2 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} y_{t-1} \\ y_{t-2} \end{pmatrix} + \begin{pmatrix} e_t \\ 0 \end{pmatrix}$$
 - hint : F 만들때 $y_{t-1} = y_{t-1}$
- 2nd step : shock에 대한 wold form으로 변형

 - $z_{t+j} = F^{j+1}z_t + \sum F^i \epsilon_{t+j-i}$
 - wold form : $z_t = \epsilon_t + \epsilon_{t-1} + F^2 \epsilon_{t-2} + \dots \rightarrow \infty$ order of shock
- 3rd step : 목표 : IR분석은 $\frac{\partial Y_{t+j}}{\partial e_t}$ 를 찾기 -> $y_t \in z_t$ 이므로

$$z_t = \begin{pmatrix} y_t \\ y_{t-1} \end{pmatrix} = \dots + \begin{pmatrix} F_{11}^j & F_{12}^j \\ F_{21}^j & F_{22}^j \end{pmatrix} \begin{pmatrix} e_{t-j} \\ e_{t-j-1} \end{pmatrix} + \dots$$

(단, sta. 가정 -> $\frac{\partial Y_{t+j}}{\partial e_t} = \frac{\partial Y_t}{\partial e_{t-j}}$)

- 즉,

$$F^j = \begin{pmatrix} \phi_1 & \phi_2 \\ 1 & 0 \end{pmatrix}^j = \begin{pmatrix} F_{11}^j & F_{12}^j \\ F_{21}^j & F_{22}^j \end{pmatrix} \Rightarrow IR$$

의 정보가 담김

 - ex) $\begin{pmatrix} y_t - (unem) \\ x_t - \Delta \mu \end{pmatrix} = \dots \begin{pmatrix} e_{1t} \\ e_{2t} \end{pmatrix}$
 - 이때 ϕ_1, ϕ_2 중 어느게 impact가 큰지를 확인 필요 -> 고유값 분해
- 4th step : 고유값분해 : $Fv = \lambda v \quad (v \neq 0)$

 - $(F - \lambda I)v = 0 \rightarrow \det(F - \lambda I) = 0$ 면 $v \neq 0$ 인 해 존재
 - 특성방정식 : $\lambda^2 - \phi_1 \lambda - \phi_2 = 0 \Rightarrow \lambda_1, \lambda_2$

 - 단, 제약조건 : $\forall \lambda_n, v_n$ 에 대해, $Fv_n = \lambda v_n, v_n' v_n = 1; n$ 개의 선형독립 필.
 - $FV = V\Lambda \Rightarrow F(v_1 \ v_2) = (v_1 \ v_2) \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix}$
 - (V : 특성 vec. 들을 모음, λ : 고유값들을 대각성분 모음)
- $F = C\Lambda C^{-1} \rightarrow F^j = C\Lambda^j C^{-1}$
- $\therefore \frac{\partial Y_{t+j}}{\partial e_t} = \frac{\partial Y_t}{\partial e_{t-j}} = ? \rightarrow F_{11}^j = \omega_1 \lambda_1^j + \omega_2 \lambda_2^j$
 - DSC : $|\lambda_n| < 1, \forall n \rightarrow \lim_{j \rightarrow \infty} \rho^j = 0$

5. unit root test

Spurious regression(가성회귀)

- 실제로는 $X \xrightarrow{X} Y$ 인데 회귀식으로 유의. $\therefore$ 두 시계열 우연히 같 방향

 - ex) 사망-혼인 정비례; -> 결혼->장수?? X. 실제로 시간 따라 우연히 동시 감소
 - 시계열에서 trend, unit root, structural break 등이 있나 의심 -> 그냥 OLS면 유의해 보이는 가짜관계

General expression for a time series variable

- time se. var. $Y_t =$ (sta. X 부분) + (sta. O 인 부분)

 - sta. O 부분 : ARMA OK
 - sta. 조건 : $E(y_t), var(y_t) \rightarrow$ 일정? (즉, $\lim_{i \rightarrow \infty} \rho_i = 0$)
 - sta. X 부분 : 강 두면 regression에 문제 O
 - TSP(Trend Stationary Process) : trend 제거 -> sta. O
 - deterministic trend : t(시간)에 따라 정확히 결정
 - 핵심 : TSP의 경우 t에 대한 다항식 부분을 빼주면 나머지는 sta. O

- Pop. EQ : $y_t = \alpha_0 + \alpha_1 t + u_t \rightarrow \hat{\alpha}_0, \hat{\alpha}_1$
 $\Rightarrow (*) (y_t - \hat{\alpha}_0 - \hat{\alpha}_1 t) : \text{stationary}$
 - sta. : $u_t : \text{sta.} \rightarrow \mu_u, \sigma_u^2$ OK
 - non sta. : t에 따라 $\alpha_0 + \alpha_1$ 평균 변화.
 - $E(u_t) = 0$ 고려? $\rightarrow$ t 고려시, sta. O($*$) 형태 stat.)
- Reg. EQ : $y_t = \alpha_0 + \alpha_1 t + \epsilon_t (\epsilon_t \stackrel{iid}{\sim} N(0, \sigma^2))$
 - $Y^* = \hat{\epsilon}_t = Y_t - \hat{\alpha}_0 - \hat{\alpha}_1 t$: Stationary OK!
 - u_t 가 sta. component 라면 ARMA OK (Lag OP. 형태로)
 - 해석 : UR X, $|\phi| < 1$
- DSP(Difference Stationary Process) : 차분 $\rightarrow$ sta. O
- stochastic trend : 확률적 추세 ($\exists$ UR.)
- 1st order 차분 $\rightarrow$ trend X
- $\phi = 1 \rightarrow$ Conven. approach(χ^2 , t-test, 등) : not work
- ex) real GDP : 경제성장 $\rightarrow Y^* \uparrow\uparrow$, 경기변동시 침체가 왜?, 어떻게 끝을?
 - $Y_t = \phi Y_{t-1} + \epsilon_t$:
 - $|\phi| = 1 \rightarrow (Y_t : \text{permanent})$; 충격=AS충격 (생산능력에 충격; 기술진보 등)
 - 의미 : (경제학적 : shock $\rightarrow$ 영구적), (계량적 : $\phi = 1 (\exists \text{unit root})$)
 - $|\phi| < 1 \rightarrow (Y_t : \text{transitory})$; 충격=AD충격 (통화/재정 정책 필)
 - (대공황) 케인지언 : AD shock $\rightarrow AD \uparrow\uparrow \rightarrow Y \uparrow\uparrow$ (by 재정정책)
 - (오쇼, 스태그 : $\pi \uparrow, Y \downarrow$) 새고전학파 : 합기 + AS 중요
 - 새케인즈 : $\therefore$ 가격경직성, 정부역할 필. $\rightarrow$ 정책이 AD 영향

Random walk Process

- URT와 DSP, RW의 관계
 - non-sta. : TSP(trend X $\rightarrow$ sta. O) or DSP(차분 $\rightarrow$ sta. O; $\exists$ UR, $\phi = 1$)
 - URT : DSP의 경우 $H_0 : \phi = 1$ 를 두고 조사
 - RW : DSP의 가장 단순한 형태
- Random walk : DSP의 대표적 예.
 - $Y_t = Y_{t-1} + u_t$; $u_t \stackrel{iid}{\sim} N(0, \sigma^2)$
 - 의미? : (통계/계량적 : $\phi = 1$ & $\exists u.r.$), (경제학적 : 공급 side의 perm. shock)
 - 성질 : $Y_t = Y_0 + \sum_{j=0}^{t-1} u_{t-j} \Rightarrow$ 충격이 영원히 지속(cummulative)
 - hint : Y_t 에 대해 재귀적 치환
 - $E(Y_t) = 0$ (if $Y_0 = 0$)
 - $Var(Y_t) = \sum_{i=1}^t Var(u_i) = t\sigma^2$: $Var()$ 가 t에 의해 바뀌므로 Non-sta. 함

- $I(p)$: Integrated of the order P
 - let, $\Delta Y_t := Y_t - Y_{t-1}$; $Y_t \sim I(1)$
 - X_t 가 차분을 p번할 시 sta. O : $X_t \sim I(p)$
 - ex) $Y_t = a + Y_{t-1} + u_t$
 $\Rightarrow ta + Y_0 + \sum_{i=0}^{t-1} u_{t-i}$; ($Y_0 = 0$)
 - 절편 $\rightarrow$ non-sta. 요소 O. shock 누적
 - a 자체가 t-t를 만들어냄
 - $\therefore ta \rightarrow$ deterministic, $\sum \dots \rightarrow$ stochastic
 - $Y_t^* = Y_t - at$ 여도, $var()$ 때문에 $\sum$ 에서 non-sta.
- General non-stationary process : $Y_t = x_t + z_t \rightarrow$ non-sta. $\therefore x_t$
 - x_t : non-sta. component
 - T-T인지? or UR인지? 혹은 혼합?
 - z_t : sta. component $\rightarrow$ AR, MA, ARMA 중 하나 OK
- **직관 : 실제 시계열은 "추세처럼 천천히 움직이는 부분"과 "그 주위에서 흔들리는 부분"이 섞여 있다고 보는 것이 편하다.**
- **예시 : GDP level은 성장추세와 경기순환이 함께 섞여 있어, 추세를 걷어내면 경기변동 부분만 볼 수 있다.**

Lag operator

- L : Lag OP.; ts. var.의 또다른 표기법
 - $L^j Y_t = Y_{t-j}$, 과거로; $L^{-j} Y_t = Y_{t+j}$, 미래로
- ARMA(p,q) :
 $Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \epsilon_t + \theta_1 \epsilon_{t-1} + \dots$
 $\epsilon_t \sim N(0, \sigma^2)$
 - $\Rightarrow Y_t = (\phi_1 L Y_t + \phi_2 L^2 Y_t + \dots) + (\epsilon_t + \theta_1 \epsilon_{t-1} + \dots)$
 - $\phi(L), \theta(L)$ 함수로 쓰면, : $\phi(L) Y_t = \theta(L) \epsilon_t$
 - where, $\phi(L) = (1 - \phi_1 L - \dots - \phi_p L^p)$,
 $\theta(L) = (1 + \theta_1 L + \dots + \theta_q L^q)$
 - $(1 - \phi L)^{-1} = \frac{1}{1 - \phi L}$
 $= 1 + \phi L + \phi^2 L^2 + \dots + \phi^j L^j + \dots$
 - 첫항 1, 공비 ϕL 의 무한급수 합 (단, $|\phi| < 1$)
 - $\phi(L) = (1 - \phi L) \rightarrow AR(1)$;
 $(1 - \phi L)^{-1} (1 - \phi L) = 1$
- ϕ, λ 간 관계와 DSC
 - AR(1) : $\phi_1 = \lambda$
 - AR(2) : sta. 조건을 찾기 위해 다시 고유값
 - $\lambda^2 - \phi_1 \lambda - \phi_2 = 0, |\lambda_n| < 1 \rightarrow sta.$
 - $\phi(L) = 0 : 1 - \phi_1 L - \phi_2 L^2 = 0$
 - 즉, $\phi(\frac{1}{\lambda}) = \phi(L) = 0$
 - 따라서 $|\lambda| < 1 \Leftrightarrow |L| > 1$ 이어야 한다.
- 왜 unit root가 있다면 conven. 분포 X?
 - let, $y_t = \phi y_{t-1} + e_t$; $e_t \stackrel{iid}{\sim} N(0, \sigma^2)$
 - $H_0 : \phi = 0, H_1 : \phi < 1$
 - $\hat{\phi}_{OLS} = \phi + \frac{\sum y_{t-1} y_t}{\sum y_{t-1}^2} \rightarrow$ 불편성?
 - but, 분포가 없? $\rightarrow$ 하나 새로 만든다

- Consistency : $\hat{\phi} \xrightarrow{p} \phi$ 가 성립하는가?(A) 분포는 뭔가 (B)?
- $\hat{\phi} = \frac{\sum y_{t-1}y_t}{\sum y_{t-1}^2} = \phi + \frac{1}{\sqrt{T}} \frac{(1) : 1/\sqrt{T} \sum y_{t-1}e_t}{(2) : 1/T \sum y_{t-1}^2}$
 - (A) 일관성 성립하냐?
 - $(T \rightarrow \infty) \quad (1) : \frac{1}{T} \sum y_{t-1}y_t \xrightarrow{p} 0; \quad (2) \frac{1}{T} \sum y_{t-1}^2 \xrightarrow{p} \text{Var}(y_t) = \gamma_0$
 - (B) 분포?
 - CLT에 의해 (2) $\rightarrow \gamma_0$
 - T 대신 $\sqrt{T}$ 를 대입하면 (수렴속도 맞춤)

$$\frac{1}{\sqrt{T}} \sum y_{t-1}e_t \xrightarrow{d} N[E(y_{t-1}e_t), (*) \text{Var}(y_{t-1}e_t)]$$
 (by CLT)
 - (*) : by LIE, $\text{Var}(y_{t-1}e_t) = E(y_{t-1}^2 e_t^2)$
 - $\rightarrow E(E(y_{t-1}^2 e_t^2 | I_{t-1})) = E(y_{t-1}^2 E(e_t^2 | I_{t-1})) = \sigma^2 E(y_{t-1}^2)$

(B) 분포 이어서 : $\hat{\phi} = \frac{\sum y_{t-1}y_t}{\sum y_{t-1}^2} = \phi + \frac{1}{\sqrt{T}} \frac{1/\sqrt{T} \sum y_{t-1}e_t}{1/T \sum y_{t-1}^2},$

$-\sqrt{T}(\hat{\phi} - \phi) \xrightarrow{d} N(0, \frac{\sigma^2}{\gamma_0}) \quad \frac{\sigma^2}{\gamma_0} = 1 - \phi^2$

-URT $\rightarrow \phi = 1$ 의 분포 : 통상적인 분포가 아니다

- 직관 : unit root면 분산이 시간에 따라 커져버려서, 평소 쓰던 normal/t 근사 논리가 그대로 작동하지 않는다.
- 예시 : random walk는 시간이 지날수록 흔들림 자체가 커지므로, stationary일 때의 t-test 기준을 그대로 적용하면 왜곡된다.
- 왜 분포가 성립하지 않나? :
 - if $\phi = 1$, $\frac{\hat{\phi} - \phi}{SE(\hat{\phi})} \sim (?)$ <Dickey-fuller dist.
 - 임계치(C.V.)를 찾는다면 OLS 가능
(CV : 유의수준 α 에 대해, $P(x) = \alpha$ 일 때의 x 값을 읽는다)
 - $\sqrt{T}(\hat{\phi} - \phi) = \frac{1/\sqrt{T} \sum y_{t-1}e_t}{1/T \sum y_{t-1}^2}$

Unit Root Test

- AR(p) : $Y_t = \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + \epsilon_t$; URT에선 다음을 테스트 :
 - $H_0 : \sum_{i=1}^p \phi_i = 1$ (Y_t : non-sta.)
 - $H_1 : \sum_{i=1}^p \phi_i < 1$ (Y_t : sta.)
- 직관 : URT의 핵심은 "충격이 결국 사라지는가, 아니면 누적되어 영구적으로 남는가"를 묻는 것이다.
- 예시 : GDP에 unit root가 있으면 경기침체 충격이 일시적 반등으로 끝나기보다 장기 수준 자체를 바꿀 수 있다.

Model 1 : Reg /w intercetp(절편O 모형)

- pop. : $Y_t = \delta + \phi Y_{t-1} + u_t$ (a)
 - $H_0 : \delta = 0 \cap \phi = 1$; $H_1 : \delta \neq 0 \cap \phi < 1$ (단, $H_1 = !H_0$ 가 맞긴 함.)
 - Reg : $\Delta Y_t = \delta + \gamma Y_{t-1} + u_t$ (let, $\Delta Y_t := Y_t - Y_{t-1}$; $\gamma = -(1 - \phi)$)
 - $H_0 : \delta = \gamma = 0$ ($Y_t \rightarrow$ non-sta.); $H_1 : !H_0$ ($Y_t \rightarrow$ sta.)

- 직관 : 여기서 핵심 검정 대상은 결국 $\gamma = 0$ 인지 여부이고, 이는 원래 모형에서 unit root가 있는지를 차분회귀로 바꿔 본 것이다.

Model 2 : Reg /w Time-trend(t-tO 모형)

- pop. : $Y_t = \delta_0 + \delta_1 t + \phi Y_{t-1} + u_t$ (b)
 - $H_0 : \delta = 0 \cap \phi = 1$; $H_1 : \delta \neq 0 \cap \phi < 1$ (단, $H_1 = !H_0$ 가 맞긴 함.)
 - H_0 하의 true Data Generating Process(DGP) $\rightarrow$ (a); H_1 하는 $\rightarrow$ (b)
 - Reg : $\Delta Y_t = \delta_0 + \delta_1 t + \gamma Y_{t-1} + u_t$ (let, $\Delta Y_t := Y_t - Y_{t-1}$; $\gamma = -(1 - \phi)$)
 - $H_0 : \delta_1 = \gamma = 0$ ($Y_t \rightarrow$ non-sta.); $H_1 : !H_0$ ($Y_t \rightarrow$ sta.)
- 직관 : 시간추세를 따로 넣는 이유는 "비정상성이 단순한 deterministic trend 때문인지, 진짜 unit root 때문인지"를 구분하려는 것이다.

Augmented Dickey Fuller (ADF) Test

- (w/i) : $Y_t = \delta + \sum_{i=1}^p \phi_i Y_{t-i} + u_t$ (w/t-t) : $Y_t = \delta_0 + \delta_1 t + \sum_{i=1}^p \phi_i Y_{t-i} + u_t$
- (w/i)나 (w/t-t) 형태의 AR(p)가 존재함. 어떻게 URT? $\rightarrow$ ADF.
 - (w/i), $p=2$; Reg : $\Delta Y_t = \delta + \gamma Y_{t-1} + \lambda_1 \Delta Y_{t-1} + u_t$
 - $\gamma = -(1 - \phi_1 - \phi_2), \lambda_1 = -\phi_2$
 - (hint : $\pm \phi_2 Y_{t-1}$ 더함, 차분형으로 만들고 Y_{t-1} 로 묶기)
 - $H_0 : \delta = \gamma = 0$ ($Y_t \rightarrow$ non-sta.); $H_1 : !H_0$ ($Y_t \rightarrow$ sta.)
 - 아래와 같이 확장하자면,
 - (w/i), $p=p$; Reg : $\Delta Y_t = \delta + \gamma Y_{t-1} + \sum_{i=1}^{p-1} \lambda_i \Delta Y_{t-i} + u_t$
 - $\gamma = -(1 - \sum_{i=1}^p \phi_i)$
 - $H_0 : \delta = \gamma = 0$ ($Y_t \rightarrow$ non-sta.); $H_1 : !H_0$ ($Y_t \rightarrow$ sta.)
 - (w/t-t), $p=p$; Reg : $\Delta Y_t = \delta_0 + \delta_1 t + \gamma Y_{t-1} + \sum_{i=1}^{p-1} \lambda_i \Delta Y_{t-i} + u_t$
 - $\gamma = -(1 - \sum_{i=1}^p \phi_i)$
 - $H_0 : \delta = \gamma = 0$ ($Y_t \rightarrow$ non-sta.); $H_1 : !H_0$ ($Y_t \rightarrow$ sta.)
 - 즉, γ 로 표현되는 $1 - \sum \phi$ 에서, 결국 $\sum \phi = 1$ 의 여부가 중요하다

- 직관 : ADF는 lagged difference를 추가해 오차의 자기상관을 흡수한 뒤에도 unit root가 남는지 보는, 더 현실적인 DF test다.
- 예시 : 실제 거시 변수는 단순 AR(1)보다 더 긴 자기상관을 가지므로, ADF는 inflation-GDP-interest rate 같은 자료에 더 자주 쓴다.