

금융계량 중간대비(lect. 6-8)

6.MLE

Maximum Likelihood Estimation

- Model : $y_i = \mu + e_i$
 - OLS Sample EQ : $y_i = \hat{\mu} + \hat{e}_i$
 - obj func of OLS(SSE) :
$$\underset{\hat{\mu}}{\operatorname{argmin}} \sum_{i=1}^N \hat{e}_i^2 = \underset{\hat{\mu}}{\operatorname{argmin}} \sum_{i=1}^N (y_i - \hat{\mu})^2$$
 - OLS estimator $\mu : \hat{\mu} = \frac{1}{N} \sum_{i=1}^N y_i$
 - $\sigma^2 : \hat{\sigma}^2 = \frac{1}{N-1} \sum_{i=1}^N (y_i - \hat{\mu})^2 (= \hat{e}_i^2)$
- Likelihood value 정의 : 특정 모수하에서, 모집단으로부터 생성된 샘플 데이터가 나올 가능성
 - $f(y; \theta) = (2\pi\sigma^2)^{-1/2} \exp\{-\frac{1}{2\sigma^2}(y - \mu)^2\}$
 $\theta = \{\mu, \sigma^2\}$
 - 샘플링 이전엔 y를 모름. 확변. μ, σ^2 주어졌다면, y에 대한 확률 추정 가능
 - PDF : 확률 추정은 PDF를 통해 가능
 - 1. $Pr(y > \mu) = \int_{\mu}^{\infty} f(y; \theta) dy = 0.5$ 2)
 $Pr(10 > y > 4) = \int_4^{10} f(y; \theta) dy$
 - (joint)JPDF of $\{y_1, \dots, y_N\}$
 $= f(y_1, \dots, y_N; \theta) \quad \theta = \{\mu, \sigma^2\}$
 - Marginal PDF of $y_i = f(y_i; \theta)$
 - r.v. A,B가 독립 $\rightarrow f(A \cap B) = f(A)f(B)$:
 $f(Y; \theta) = \prod_{i=1}^N f(y_i; \theta) \quad Y = (y_1 \dots y_N)^T$
 - if $y_i \stackrel{iid}{\sim} N(\mu, \sigma^2)$, then
 $f(Y; \theta) = (2\pi\sigma^2)^{-N/2} \exp\{-\frac{1}{2\sigma^2} \sum_i (y_i - \mu)^2\}$
- Likelihood function :
 $L(\mu, \sigma^2 | y_1, \dots, y_N) = f(y_1, \dots, y_N; \mu, \sigma^2)$
 - MLE의 목적함수는 $\underset{\mu, \sigma^2}{\operatorname{argmax}} \ln L(\mu, \sigma^2 | Y)$
 - $\ln()$: 단조증가? $\rightarrow$ 합성해도 해가 달라지지 X.
 - FOC of MLE : $\frac{\partial \ln L(\theta | Y)}{\partial \theta} = 0$: MLE는 FOC를 통해 모수들을 추정
- MLE example : $y_i = X_i' \beta + e_i$
 - y_i 분포 : $y_i \sim N(X_i' \beta, \sigma^2)$
 - $f(y_i)$? (y_i 의 pdf?) :
 $f(y_i; \beta, \sigma^2) = 1/\sqrt{2\pi\sigma^2} \exp\{-\frac{(y_i - X_i' \beta)^2}{2\sigma^2}\}$
 - Y의 JPDF? : $f(Y; \beta, \sigma^2) = \prod_{i=1}^N f(y_i; \beta, \sigma^2)$
 $= (2\pi\sigma^2)^{-N/2} \exp\{-\frac{\sum_{i=1}^N (y_i - X_i' \beta)^2}{2\sigma^2}\}$
 - $L \rightarrow \ln L$:
 $\ln L(\beta, \sigma^2 | Y) = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{\sum_{i=1}^N (y_i - X_i' \beta)^2}{2\sigma^2}$
 - $\frac{\partial \ln L}{\partial \theta} = 0$:
 $\rightarrow \hat{\beta}_{MLE} = \hat{\beta}_{OLS} \quad \text{but, } \hat{\sigma}_{MLE}^2 = \frac{1}{n} \sum \hat{e}_i^2$

MLE generalization

- $\hat{\theta}_{MLE} = \underset{\theta}{\operatorname{argmax}} \ln L(\theta | Y)$
- 랜덤 샘플링시 LL(log likelihood) :
 $\ln L(\theta | Y) = \ln(\prod_{i=1}^n f(y_i; \theta)) = \sum_{i=1}^n \ln f(y_i; \theta)$
- FOC of MLE :
 $\forall \theta_i \in \theta = \{\theta_1, \dots, \theta_k\}, \quad \frac{\partial \ln L(\hat{\theta}_{MLE} | Y)}{\partial \theta_i} = 0$
- score vector :
 $S(\theta | Y) = \frac{\partial \ln L(\theta | Y)}{\partial \theta}, \quad S(\hat{\theta}_{MLE} | Y) = 0$
- LL func for linear reg model :
 $\ln L(\theta | y, X) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} (y - X\beta)'(y - X\beta) \Rightarrow \frac{\partial \ln L(\theta | y, X)}{\partial \theta} = 0$
 - $\hat{\beta}_{MLE} = (X'X)^{-1} X'y = \hat{\beta}_{OLS}$
 - but, $\hat{\sigma}_{MLE}^2 = \frac{1}{n} (y - X\hat{\beta}_{MLE})'(y - X\hat{\beta}_{MLE}) \neq \hat{\sigma}_{OLS}^2 = \frac{1}{n-k} (y - X\hat{\beta}_{OLS})'(y - X\hat{\beta}_{OLS})$
 - 단, n의 크기가 커질수록 서로간 오차가 미미해짐

MLE for series data

- IID ts의 LL : $\ln L(\theta | y) = \sum_{t=1}^T \ln f(y_t; \theta)$
- 시계열의 경우 오차가 IID X. (독립X)
 - $\therefore$ 교사건 확률을 조건부 확률로 표현 :
 $p(A \cap B) = p(B|A)p(A)$
 $P(A \cap B \cap C) = p(C|A \cap B)p(B|A)p(A)$
 - ts에선, :
 $f(y_T, \dots, y_1; \theta) = \{\prod_{t=p+1}^T f(y_t | I_{t-1}; \theta)\} \cdot f(y_p, \dots, y_1; \theta)$
 - $I_t = \{y_t, \dots, y_1\}$: t시점의 가능한 정보
 - $y_p, \dots, y_1$: p개의 초기 관측치
 - $\therefore$ LL 에서 :
 $\ln L(\theta | y) = \sum_{t=p+1}^T \ln f(y_t | I_{t-1}; \theta) + \ln f(y_p, \dots, y_1; \theta)$
 $\hat{\theta}_{MLE} = \underset{\theta}{\operatorname{argmax}} \ln L(\theta | y)$
 - hint : 과거 I_{t-1} 로 설명된 부분 제거 $\rightarrow$ 새 innovation만 density로 평가

MLE for AR(1) model

- sta.한 AR(1) 모델 :
 $y_t = c + \phi y_{t-1} + \epsilon_t; \quad \epsilon_t \stackrel{IID}{\sim} N(0, \sigma^2) | \phi| < 1$
 - $y_t | I_{t-1} \sim N(c + \phi y_{t-1}, \sigma^2)$
 - conditional LL : $\ln L_c(\theta | y)$
 $= \sum_{t=2}^T \left[-\frac{1}{2} \ln(2\pi) - \frac{1}{2} \ln \sigma^2 - \frac{(y_t - c - \phi y_{t-1})^2}{2\sigma^2} \right]$
 - 초기값 y_1 처리 : conditional MLE는 $f(y_1)$ 생략; exact MLE는 $f(y_1; \theta)$ 포함
 - sta. hint :
 $|\phi| < 1, \quad E(y_t) = \frac{c}{1-\phi}, \quad Var(y_t) = \frac{\sigma^2}{1-\phi^2}$

MLE for ARMA(p,q)

- ARMA(p,q) :
 $y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \epsilon_t + \sum_{j=1}^q \theta_j \epsilon_{t-j}$
 $\epsilon_t \sim N(0, \sigma^2)$
 - 핵심 : $y_t | I_{t-1} \sim N(\mu_{t|t-1}, \sigma^2)$
 - $\mu_{t|t-1} = c + \sum_i \phi_i y_{t-i} + \sum_j \theta_j \epsilon_{t-j}$
 - LL : $\ln L_c = \sum_{t=m+1}^T \ln f(y_t | I_{t-1}; \theta)$
 $m = \max(p, q)$
 - AR part : 과거 y 직접 관측 O / MA part : 과거 ϵ 관측 X -> recursion/초기값 필요
 - 함의 : 식은 regression처럼 보여도 ϵ_{t-j} 가 모수 의존 -> closed form 보통 X

Newton-Raphson method & numerical optimization

- 왜 필요? : 복잡한 ML은 FOC 손풀이/closed form X -> 컴퓨터가 LL surface에서 peak search
- global vs local max
 - global max : 전체 구간 최고점
 - local max : 주어진 초기값/탐색구간 근처 최고점
 - 실증 hint : initial value/grid 바꿔보기; 말 안 되는 parameter range 주의
- Newton-Raphson : 현재점에서 gradient+curvature로 다음점 update
 - $\theta^{(k+1)} = \theta^{(k)} - [H(\theta^{(k)})]^{-1} S(\theta^{(k)})$
 - $S(\theta) = \partial \ln L / \partial \theta$: score(기울기)
 - $H(\theta) = \partial^2 \ln L / \partial \theta \partial \theta'$: Hessian(곡률)
 - max에서 $S(\hat{\theta}) = 0$, $H(\hat{\theta})$ negative definite
- 정보행렬 : $I(\theta) = -E[H(\theta)]$
 - curvature 큼 -> peak sharp -> estimator var 작음
 - curvature 작음 -> peak flat -> estimator var 큼

MLE asymptotic properties

- large sample에서 MLE
 - consistent : $\hat{\theta}_{MLE} \xrightarrow{p} \theta_0$
 - asym. normal : $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} N(0, I(\theta_0)^{-1})$
 - asym. efficient : large sample에서 var. 작음 (Cramer-Rao lower bound)
- 강의 직관 : sample $\uparrow$ -> 추정분포 좁아짐; normal approx 가능; information matrix inverse가 분산
- OLS와 관계
 - classical linear normal model -> $\hat{\beta}_{MLE} = \hat{\beta}_{OLS}$
 - $\hat{\sigma}_{MLE}^2 = SSR/n$, $\hat{\sigma}_{OLS}^2 = SSR/(n-k)$ -> small sample 차이, n 커지면 미미

백지복원

- MLE : data Y 고정, parameter θ 바뀌
 $L(\theta|Y) = f(Y; \theta)$ max.
- PDF/JPDF와 수학형태 같지만 해석 방향 반대. iid면
 $\ln L = \sum_i \ln f(y_i; \theta)$; ts dep. 있으면 chain rule로
 $\ln L = \sum_t \ln f(y_t | I_{t-1}; \theta) + initial.$
- AR(1)은 $y_t | I_{t-1} \sim N(c + \phi y_{t-1}, \sigma^2)$ 라 conditional LL 구성.
- ARMA는 MA error가 관측 X라 recursion 필요, closed form 대개 X -> Newton-Raphson 등 numerical opt. 사용.
- max에서 score=0, Hessian/information matrix가 곡률 및 estimator var 정보 제공.
- large sample MLE : consistent, asym. normal, efficient.

7. GARCH

Idea

- GARCH : R_t 의 time-varying vola.(volatility) + vola. clustering 설명 -> 조건부 분산 모형화
- 기존 : $y_t = x_t' \beta + \epsilon_t$, $\epsilon_t \sim (0, \sigma^2)$
- GARCH : $\epsilon_t | I_{t-1} \sim (0, \sigma_t^2)$ -> 분산도 I_{t-1} 따라 update
- 금융 data 특징 : time-varying vola. / vola. clustering / fat tail / asym.(asymmetry, leverage)
- 핵심 : 수익률 평균만 맞 X, 잔차 분산이 어떻게 진화?

Conditional Moment

- I_t : t 까지 이용 가능 info. set
 - 이미 알려진 정보 -> shock X, condition
 - shock : 예상 못 한 부분
 - LIE : 큰 info. 안의 rv는 상수취급; nested info. -> smaller set wins
- 조건부 평균/분산 :
 $\mu_{t+1|t} = E(r_{t+1} | I_t)$, $\sigma_{t+1|t}^2 = Var(r_{t+1} | I_t)$
- vola. : $\sigma_{t+1|t} = \text{conditional std.}$
- 표준화 : $z_t = \epsilon_t / \sigma_t$, $z_t \stackrel{iid}{\sim} (0, 1) \Rightarrow \epsilon_t = \sigma_t z_t$
 - $\epsilon_t = \text{shock size}(z_t) \times \text{vola. scale}(\sigma_t)$

Mean Eq.

- 기본 : $y_t = \mu + \epsilon_t$
- with regressor : $y_t = x_{t-1}' \beta + \epsilon_t$, $\epsilon_t = \sigma_t z_t$
 - $x_{t-1} : x_t - \epsilon_t$ 동시성관 회피
- mean side : ARMA/exog 가능; 관심 : residual의 σ_t^2 law of motion

ARCH

- ARCH : Autoregressive Conditional Heteroskedasticity
 - AR : 과거 shock 사용 / C : I_{t-1} 조건부 / H : 이분산
- ARCH(1) : $\sigma_t^2 = \alpha_0 + \alpha_1 \epsilon_{t-1}^2$
 - 어제 큰 잔차 -> 오늘 큰 조건부 분산
- ARCH(p) : $\sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i \epsilon_{t-i}^2$
 - 과거 p 기 shock 크기 -> 현재 vola.
- 조건 : $\alpha_0 > 0, \alpha_i \geq 0, \sum_i \alpha_i < 1$
 - 앞 둘 : 분산 음수 X / 마지막 : 발산 X
- Uncond. var. : $E(\sigma_t^2) = \frac{\alpha_0}{1 - \sum_i \alpha_i}$
 - 복원 hint : ARCH식 양변 $E(\cdot)$ -> conditional 변해도 장기 평균분산 O

GARCH

- ARCH 한계 : 긴 vola. persistence 설명하려면 고차항 많이 필요
- GARCH : 과거 shock + 과거 vola. 자체
 - $GARCH(p, q) : \sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \epsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2$
 - ARCH term : ϵ_{t-i}^2 = new shock
 - GARCH term : σ_{t-j}^2 = vola. persistence
- GARCH(1,1) : $\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2$
 - α : 새 shock 영향 / β : 과거 vola. 지속 / $\alpha + \beta$: persistence
- 조건/장기분산 :

$$\omega > 0, \alpha, \beta \geq 0, \alpha + \beta < 1, E(\sigma_t^2) = \frac{\omega}{1 - \alpha - \beta}$$
 - $\alpha + \beta \approx 1$ -> shock 오래 감
- 실증 기본 : GARCH(1,1)부터; high order 남발 X(noisy + 추정불안정)

GARCH-in-Mean

- idea : high risk -> high return? vola.가 기대수익률에 직접 영향
- $y_t = x'_{t-1} \beta + \lambda g(\sigma_t^2) + \epsilon_t, g \in \{\sigma_t, \sigma_t^2, \log \sigma_t^2\}$
- $\lambda > 0$: risk↑ return↑ / $\lambda < 0$: risk↑ return↓

Asymmetric GARCH

- 기본 GARCH : ϵ_{t-1}^2 -> +5, -5 동일 취급
- 현실 : bad news -> good news보다 vola.↑ 가능
- EGARCH :

$$\log \sigma_t^2 = \omega + \beta \log \sigma_{t-1}^2 + \alpha (|z_{t-1}| - E|z_{t-1}|) + \gamma z_{t-1}$$
 - log var. -> 양수제약 자연 처리

- γ : shock sign 효과; 보통 $\gamma < 0$ -> negative shock가 vola.↑

- TGARCH/GJR :

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \gamma I(\epsilon_{t-1} < 0) \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$
 - positive shock : α / negative shock : $\alpha + \gamma$
 - $\gamma > 0$ -> negative shock 추가효과 O

Exogenous Vol. Factor

- 외생 factor : 금리기대, FX, 거래량, 뉴스빈도, overnight R, implied vola., 지정학 risk
- 예시 : $\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2 + \delta z_{t-1}$
- 주의 : 변수 많이 넣기 X -> data 충분? 경제적 설명? graph상 variation?

MLE

- vola. 직접 관측 X : σ_t^2 는 residual 기반 latent object -> OLS X, MLE O
- 정규가정 : $\epsilon_t | I_{t-1} \sim N(0, \sigma_t^2)$
- log-likelihood :

$$\ell(\theta) = \sum_t [-\frac{1}{2} \log(2\pi) - \frac{1}{2} \log \sigma_t^2 - \frac{\epsilon_t^2}{2\sigma_t^2}]$$
- 절차 : mean eq. 설정 -> GARCH recursion으로 σ_t^2 생성 -> conditional PDF -> LL maximize
- fat tail 강함 -> Normal 대신 Student-t 등

Multivariate GARCH

- 1 asset : σ_t^2 scalar
- N assets : $r_t \in \mathbb{R}^N, \Sigma_t \in \mathbb{R}^{N \times N}$
 - 관심 : 개별 vola. + cov/corr 시간변화
- BEKK / CCC(Constant Conditional Corr.) / DCC(Dynamic Conditional Corr.)
- DCC : $\Sigma_t = D_t R_t D_t$
 - D_t : cond. std. diagonal / R_t : cond. corr.
 - CCC : R fixed / DCC : R_t time-varying

백지복원

- GARCH : R_t 의 time-varying vola. + clustering 설명 -> σ_t^2 모형화.
- mean eq. :

$$y_t = x'_{t-1} \beta + \epsilon_t, \epsilon_t = \sigma_t z_t, z_t \sim iid(0, 1).$$
- ARCH : $\sigma_t^2 = \alpha_0 + \sum_i \alpha_i \epsilon_{t-i}^2$ -> 과거 shock 크기 반영.
- GARCH(1,1) : $\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2$.
- α = new shock, β = persistence, $\alpha + \beta < 1, E(\sigma_t^2) = \omega / (1 - \alpha - \beta)$.
- σ_t^2 관측 X -> conditional PDF + MLE. sign 효과 필요 -> EGARCH/TGARCH.

8. Vector Auto-Regression (VAR)

Idea

- VAR : 여러 sta.(stationary) ts를 **vector로 묶은 AR**
 - scalar AR : $y_t = c + \phi y_{t-1} + e_t$
 - VAR :
$$Y_t = A_0 + A_1 Y_{t-1} + \dots + A_p Y_{t-p} + u_t$$
- 왜? : 경제 shock는 한 변수에만 X, 여러 시장/부문에 동시 전파
 - ex) 금리 shock $\rightarrow \pi_t$, GDP, 실업률, 환율 등 같이 움직임
 - partial eq. 직관(*ceterisparibus*) 약함 $\rightarrow$ system으로 같이 추정
- VARMA? 가능하지만 복잡 $\rightarrow$ 보통 VAR로 approx.
- 주의 : 변수 “막” 넣기 X $\rightarrow$ 경제이론/데이터 variation/추정가능성 필요

Before VAR

- 전제 : VAR 기본형은 sta. 변수 사용
 - unit root test $\rightarrow$ non-sta.면 차분/성장률/추세제거
 - 정보손실 걱정? non-sta. 그대로 쓰는 모형 : VECM, UC 등
- 변수 선택 : 같이 움직일 경제적 이유 O?
- lag order : 너무 크게 X
 - 변수 수 $\uparrow$, lag $\uparrow$ $\rightarrow$ parameter 폭증 $\rightarrow$ 추정불안정/비경제적 부호
 - 실증 hint : 데이터 graph + theory + IC(AIC/BIC) + robustness

VAR(p)

- $Y_t = (y_{1t}, \dots, y_{nt})'$
- reduced-form VAR(p)
 - $Y_t = c + A_1 Y_{t-1} + \dots + A_p Y_{t-p} + u_t$
$$E(u_t) = 0, \quad E(u_t u_t') = \Sigma_u$$
- each eq. : 같은 RHS($Y_{t-1}, \dots, Y_{t-p}$) $\rightarrow$ eq별 OLS 가능
 - OLS처럼 쉬움; 어려운 건 변수/lag/식별/해석
- 활용
 1. dynamics 파악 : 변수간 lead-lag
 2. forecast : 과거 Y로 미래 경로 예측
 3. policy/shock analysis : shock가 각 변수에 퍼지는 경로(IRF)

Reduced Form vs Structural Form

- foundation : simultaneous eq.(수요/공급처럼 동시결정); 관측은 구조곡선 X, 균형값 O
- reduced form : data로 바로 추정 가능
 - $Y_t = c + \sum_i A_i Y_{t-i} + u_t$
 - u_t 끼리 동시상관 가능 : Σ_u non-diagonal
 - reduced coeff. 자체를 causal structural effect로 읽기 X
- structural form : 경제 구조/동시관계 포함
 - $B_0 Y_t = b + \sum_i B_i Y_{t-i} + \varepsilon_t, \quad E(\varepsilon_t \varepsilon_t') = D$
 - ε_t : structural shock, 서로 orthogonal하게 해석하고 싶음
- 연결
 - $Y_t = B_0^{-1} b + \sum_i B_0^{-1} B_i Y_{t-i} + B_0^{-1} \varepsilon_t$
 - $u_t = B_0^{-1} \varepsilon_t, \quad \Sigma_u = B_0^{-1} D (B_0^{-1})'$
- 핵심 문제 : reduced form은 추정 O, structural shock은 바로 관측 X $\rightarrow$ identification 필요

Normalization / Identification

- 단순 예
 - $\alpha^* y_t = \beta^* X_t + e_t, \quad e_t \sim N(0, \sigma^{*2})$
 - $y_t = \frac{\beta^*}{\alpha^*} X_t + \frac{e_t}{\alpha^*} = \beta X_t + \epsilon_t$
$$Var(\epsilon_t) = \sigma^{*2} / \alpha^{*2}$$
- 함의 : $(\alpha^*, \beta^*, \sigma^{*2})$ 여러 조합 $\rightarrow$ 같은 (β, σ^2) 가능
 - structural unknown 3개, reduced-form info 2개 $\rightarrow$ 식별불가
- 해결 : 모르는 것 하나를 normalize/restrict
 - $\alpha^* = 1$ 또는 $\sigma^{*2} = 1$
 - VAR에서도 structural parameter 수 > reduced-form moments $\rightarrow$ 제약 필요
- 식별 직관 : 관측되는 건 균형값/축약형 shock; 수요/공급/정책 shock는 구조제약 없이는 분리 X

Recursive / Cholesky Identification

- 목적 : $\Sigma_u = PP'$ 인 P 를 찾아
$$u_t = P \varepsilon_t, \quad Var(\varepsilon_t) = I$$
- Cholesky : P lower triangular $\rightarrow$ ordering으로 동시반응 제약 부여
 - 위에 둔 변수 : 같은 시점에 뒤 변수 shock에 즉시 반응 X
 - 아래 변수 : 앞 변수 shock에 즉시 반응 O
- 함의 : variable ordering = 경제적 가설
 - 순서 바꾸면 IRF 달라질 수 있음 $\rightarrow$ theory로 justify 필요
- shock scale : 보통 1 s.d. shock; 보고서용은 1% shock로 normalize 가능

IRF(Impulse Response Function)

- IRF : structural shock 1회 발생 -> 각 변수의 미래 반응 경로
 - ε_{jt} 1단위/1 s.d. shock -> Y_{t+h} 변화
- VAR(1) intuition
 - $Y_t = A_1 Y_{t-1} + u_t, \quad u_t = P \varepsilon_t$
 - h 기 반응 : $\partial Y_{t+h} / \partial \varepsilon_t = A_1^h P$
- 해석 hint
 - 금리↑ shock -> 이론상 $\pi \downarrow$, output↓, unemployment↑ 예상
 - 초기 반응 이상하면? ordering/변수/proxy/lag/sample 문제 의심
 - 실업률 등 slow-moving 변수는 즉시반응 작고 후행 가능
- 장기효과
 - sta. VAR이면 shock 효과는 시간이 지나며 0으로 수렴
 - 정책은 주로 cycle에 영향, trend 영구효과 주장은 별도 이론 필요

Forecast / FEVD

- Forecast : $\hat{Y}_{T+h}$ 를 VAR recursion으로 생성
 - in-sample fit 좋음 ≠ forecast 좋음
 - forecast error가 새 info. update의 핵심
- FEVD(forecast error variance decomposition)
 - h 기 예측오차 분산 중 각 shock가 설명하는 비중
 - “어떤 shock가 변동을 주로 설명?” 질문

Practical Checklist

- 1. data plot : 충분한 variation O?
- 2. stationarity check : unit root -> 차분/성장률/추세제거 or VECM/UC
- 3. variables : theory로 묶기; proxy 필요시 검토
- 4. lag order : 너무 크게 X, IC/robustness
- 5. reduced-form VAR estimate : eq별 OLS
- 6. identification : Cholesky/order/restriction 명시
- 7. IRF/FEVD : shock 방향/scale/ordering 해석

백지복원

- VAR : Y_t vector의 AR. 경제 shock는 여러 변수에 동시 전파 -> scalar eq.보다 system 필요.
- reduced-form : $Y_t = c + \sum_i A_i Y_{t-i} + u_t$, sta. 변수 사용, eq별 OLS 가능.
- u_t 는 reduced-form shock -> structural policy shock 아님.
- structural form :
$$B_0 Y_t = b + \sum_i B_i Y_{t-i} + \varepsilon_t, \quad u_t = B_0^{-1} \varepsilon_t$$
- ε_t 복원 필요 -> identification.
- reduced-form moments만으론 structural parameter 부족 -> normalization/restriction.
- Cholesky : ordering으로 동시반응 제약, $u_t = P \varepsilon_t$ 분해.
- IRF : shock 1회가 미래 Y_{t+h} 에 미치는 경로; VAR(1) -> $A_1^h P$.
- 변수/lag/order 막 넣기 X -> stationarity, theory, data variation 확인.