

계량경제학 강의 2

표본평균과 표본분산

1. 모형의 설정


- 모평균 : $E(y_i) = \mu$
- 모분산 : $Var(y_i) = E((y_i - \mu)^2) = \sigma^2$

- 표본평균 : $\hat{\mu} =$ ~~~~~
- 표본분산 : $\hat{\sigma}^2 =$ ~~~~~

가정: 분산성질을 다루는 식은
가정 → ① 예는 ② 가설 검증

- 우리의 모형(키)는 하에,
Q1) $\hat{\mu}, \hat{\sigma}^2$ 어디서 나온 공식인가?
Q2) 우리가 믿을 수 있는 공식인가?
Q3) $\hat{\mu} \neq \mu$, 단 한 번의
↓
과 관련한 불확실성?

1. 모형의 설정



- 확률변수 y_i 가 취할 수 있는 모든 값들의 평균이 μ : $E(y_i) = \mu$ (true value μ)

$$= \frac{1}{N} \sum_{i=1}^N y_i$$
- 분산이 σ^2 : $Var(\underline{y_i}) = \sigma^2$

이라고 할 때 다음의 간단한 모형으로 나타낼 수 $y_i = \mu + e_i$ 있다.

Population equation : $\underline{Y_i} = \underline{\mu} + \underline{e_i}$ ($i=1, 2, \dots, N$)

Assumption :

- ① $E(e_i) = 0, \forall i$ (error term)
- ② $E(e_i^2) = \sigma^2, \forall i$ (var. definition, avg. V)
- ③ $E(e_i \cdot e_j) = 0, \forall i \neq j$ (cov. V)

$$y_i - \mu = \frac{e_i}{\frac{1}{N} \sum_{i=1}^N 1}$$


$$E(y_i) - E(\mu) = 0$$

2. 최소제곱법(OLS)


• 최소제곱법(OLS: Ordinary Least Squares)

: 잔차항의 제곱의 합을 극소화 하는 방법

< population > (N)
(그래프)



< sample >
 n : # of sample



형식에서는 $\hat{M} \approx M$
by OLS $y = \hat{M} + \hat{e}_i$ $\sim$ 최소화
 $\hat{e}_1 + \hat{e}_2 + \dots + \hat{e}_n$
 $\text{Min } \frac{n}{2} \hat{e}_i^2$ with respect to $\hat{M}$

2. 최소제곱법(OLS)

- 표본회귀식(sample regression equation)

$$y_i = \hat{\mu} + \hat{e}_i$$

- OLS 추정량 유도

- 특히
- ① $E(\hat{e}_i) = 0 \quad \forall i$
 - ② $E(\hat{e}_i^2) = \sigma^2 \quad \forall i$
 - ③ $E(\hat{e}_i \cdot \hat{e}_j) = 0 \quad \forall i \neq j$

$$\sum \hat{e}_i^2 = \sum (y_i - \hat{\mu})^2$$

$\Rightarrow$ f.o.c)

$$\sum_{i=1}^n 2(y_i - \hat{\mu})(-1) = 0$$

$$\Rightarrow \sum (y_i - \hat{\mu}) = 0$$

$$\sum y_i - n \cdot \hat{\mu} = 0$$

$$\therefore \hat{\mu} = \frac{1}{n} \sum y_i$$

사전 ex-ante	사후 ex-post
$\hat{\mu} = \frac{1}{n} \sum y_i$ estimation, 평균 추정 변수.	$\hat{\mu} = \frac{1}{n} \sum y_i$ estimate. ↓ 추정량 추정치 값 또.

3. OLS 추정량의 불편성

Repeated Sampling 에서, 평균적으로 $\hat{\mu}$ 은 μ 라는 값을 준다.
 $Q \quad E(\hat{\mu}) = \mu ?$

• 불편성(unbiasedness) : $E(\hat{\theta}) = \theta$

• OLS 추정량의 불편성:

$$E(\hat{\mu}) = \mu ?$$

$$\textcircled{1} \quad E\left(\frac{1}{n} \sum Y_i\right)$$

$$= E\left(\frac{1}{n} (Y_1 + Y_2 + \dots + Y_n)\right)$$

$$= \frac{1}{n} (E(Y_1) + \dots + E(Y_n))$$

$$= \frac{1}{n} \cdot n \cdot \mu \quad \therefore E(\hat{\mu}) = \mu$$

성립한다면 $\hat{\mu}$ 은 μ 의

Unbiased Estimator라 부른다.
(불편 추정량)

②

$$E(\hat{\mu})$$

$$= E\left(\frac{1}{n} \sum Y_i\right)$$

$$= \frac{1}{n} E\left(\sum (\mu + e_i)\right)$$

$$= \frac{1}{n} (n \cdot \mu + E(\sum e_i))$$

$$= \frac{1}{n} \cdot n \cdot \mu + \frac{1}{n} (E(e_1) + E(e_2) + \dots + E(e_n))$$

〇 by assumption ①


population Equation

$$\therefore E(\hat{\mu}) = \mu$$

4. OLS 추정량의 분산

$\mu \neq \hat{\mu}$, 한 번의 실험
 $\hat{\mu}$ 와 관련된 불확실성

+가정 : $E(e_i e_j) = 0, i \neq j$



$$\begin{aligned}
 \bullet \text{ } \underline{Var}(\hat{\mu}) &= E[(\hat{\mu} - E(\hat{\mu}))^2] \\
 &\stackrel{\text{by def.}}{=} E[(\hat{\mu} - \mu)^2] \\
 &\stackrel{\text{by OLS}}{=} E\left[\left(\frac{1}{n} \sum Y_i - \mu\right)^2\right] \\
 &= E\left[\left(\frac{\sum Y_i - n\mu}{n}\right)^2\right] \\
 &\stackrel{e_i}{=} E\left[\left(\frac{\sum (Y_i - \mu)}{n}\right)^2\right] \\
 &= E\left[\left(\frac{\sum e_i}{n}\right)^2\right] \\
 &= \frac{1}{n^2} E[e_1^2 + e_2^2 + \dots + e_n^2] \\
 &= \frac{1}{n^2} \cdot n\sigma^2 \\
 &= \left(\frac{\sigma^2}{n}\right)
 \end{aligned}$$

$$\therefore Var(\hat{\mu}) = \frac{\sigma^2}{n}$$

$$\underline{E(e_i^2) = \sigma^2 \quad \forall i}$$

σ^2 의 추정?

6. 표본분산의 평균

$$\text{Var}(\hat{\mu}) = \frac{\sigma^2}{n}$$

σ^2 의 추정!

(1) μ 가 알려져 있는 경우

→ 모평균 μ known

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n e_i^2$$

Recall ii) $E(e_i^2) = \sigma^2 \quad \forall i$

(WTS) $E(\hat{\sigma}^2) = \sigma^2$ 을
만족하는 $\hat{\sigma}^2$ 은 ?

$$E(e_1^2 + e_2^2 + \dots + e_n^2) = n \cdot \sigma^2$$

$\hat{\sigma}^2$

$$E\left(\frac{\sum e_i^2}{n}\right) = \sigma^2$$

(pop. eqn) $\underline{Y_i} = \underline{\mu} + e_i$ ✓

(Sample) Data known

→ e_i 는 안다

$$\hat{\sigma}^2 = \frac{1}{n} e_i^2$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum (Y_i - \mu)^2$$

이 때 $\hat{\sigma}^2$ 은 σ^2 의 unbiased Estimator

6. 표본분산의 평균

(2) μ 가 알려져 있지 않은 경우

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n e_i^2$$

증명) $\sum_{i=1}^n e_i^2 =$

Q) $E(\hat{\sigma}^2) = \sigma^2$ 이
되는 $\hat{\sigma}^2$ 을 구하라

→ 우리는 μ 가 unknown 이므로
대신 $\hat{\mu}$ 을 이용한다.

sample) $Y_i = \hat{\mu} + \hat{e}_i$, $\hat{e}_i = Y_i - \hat{\mu}$

$\hat{e}_i^2 = (Y_i - \hat{\mu})^2$ 을 사용해야 한다

$$\underline{\underline{e_i}} = \underbrace{(Y_i - \hat{\mu})}_{\hat{e}_i} + (\hat{\mu} - \mu)$$

$$e_i = \hat{e}_i + \underline{(\hat{\mu} - \mu)} \quad \text{--- 식 ①}$$

6. 표본분산의 평균

(2) μ 가 알려져 있지 않은 경우

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n e_i^2$$

증명) $\sum_{i=1}^n e_i^2 =$

$$\begin{aligned}
 E\left(\sum_{i=1}^n e_i^2\right) &= E\left(\sum_{i=1}^n (\hat{e}_i + (\hat{\mu} - \mu))^2\right) \\
 &= E\left[\sum \hat{e}_i^2 + (\hat{\mu} - \mu)^2 + 2 \cdot \hat{e}_i (\hat{\mu} - \mu)\right] \\
 &\quad \left(\because 2 \cdot \sum \hat{e}_i (\hat{\mu} - \mu) \text{ (OLS) F.O.C } \frac{\partial \sum \hat{e}_i^2}{\partial \hat{\mu}} = 0; \sum \hat{e}_i = 0\right) \\
 &= E\left[\sum \hat{e}_i^2 + \sum (\hat{\mu} - \mu)^2\right] \\
 &= E(\sum \hat{e}_i^2) + \sum \text{var}(\hat{\mu}) \\
 &= E(\sum \hat{e}_i^2) + n \cdot \frac{\sigma^2}{n}
 \end{aligned}$$

$$\begin{aligned}
 E(e_i^2) &= \sigma^2 \\
 \text{var} & \\
 E(\sum e_i^2) &= E(\sum \hat{e}_i^2) + \sigma^2 \\
 n \cdot \sigma^2 &= E(\sum \hat{e}_i^2) + \sigma^2
 \end{aligned}$$

6. 표본분산의 평균

$$(n-1) \sigma^2 = E(\hat{e}_i^2)$$

$$\therefore E(\hat{\sigma}^2) = \sigma^2$$

(2) μ 가 알려져 있지 않은 경우

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n e_i^2$$

$$\text{증명) } \sum_{i=1}^n e_i^2 =$$

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum \hat{e}_i^2$$

μ : unknown

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum \hat{e}_i^2 \quad \leftarrow \hat{\mu} \text{ is used}$$

μ : known $\Leftrightarrow e_i$ is known

$$\hat{\sigma}^2 = \frac{1}{n} \sum \underline{e_i^2}$$