

계량경제학 강의 6

단순회귀모형(1)

1. 단순회귀모형

- 선형 모형: 두 변수에 선형(직선형, 1차 함수) 관계를 설정한 모형
 - 예: 임금 = $a + b * \text{학력} + \text{여타 요소들의 영향}$
 - 일반적으로 $Y = a + b * X + e$ 로 표현함(이와 같이 e 를 합산한다는 것도 선형모형의 조건)

선형모형은 선형 관계를 설정하므로 제한적일 수 있으나, 변수들의 함수형태를 유연하게 하여 일반화시킬 수 있으므로 여전히 매우 유용함

1. 단순회귀모형

- 어떤 변수들이 다른 변수에 영향을 미치는 것을 나타내는 방정식을 "회귀식" 또는 "회귀방정식"이라 하고, 이런 영향을 찾는 것을 "회귀분석"이라 함
- 관례상, 원인이 되는 변수를 우변에 쓰고 그 결과 영향을 받는 변수를 좌변에 나타냄
 - $Y = a + b * X + e$ 이면 X가 원인이 되는 변수이고 Y가 그 결과 영향을 받는 변수임
 - 이는 "X가 한 단위 변화하면 Y가 어느 정도 영향을 받느냐"를 표현할 때 사용됨
- $Y = a + b * X + e$ 라는 모형을 세우고 분석하는 것을 "Y를 X에 대하여 회귀한다" (regress Y on X)고 표현함

1. 단순회귀모형

- 단순 선형회귀 모형: 두 변수 간의 선형 관계를 나타내는 모형
 - 2변수 선형회귀 모형이라고도 함
 - 편의상 a 와 b 를 β_0 과 β_1 이라 쓰면 다음이 됨

설명변수, 독립변수, 통제변수,
우변변수, 예측변수, 회귀변수

피설명변수, 종속변수, 반응변수, 좌변변수, 피예측변수, 피회귀변수

$$Y = \beta_0 + \beta_1 X + e$$

오차항, 교란항

- X 는 원인, Y 는 결과, u 는 여타 요소들이 Y 에 미치는 영향
- B_0 : 절편, β_1 : 기울기


• 모수의 해석

- B_1 : e 가 고정될 때 X 가 1 단위 증가하면 Y 는 β_1 단위 증가함 (인과적 영향)
- β_0 : e 의 값이 0이고 X 의 값이 0이면 Y 값은 β_0

1. 단순회귀모형


$$GDP=C+I+G+(Nx)$$

예) 소득과 소비의 관계



소득이 100만원인 사람들

-> () : $Y^P \rightarrow C$



소득이 200만원인 사람들

$E(Y|X)=?$

1. 단순회귀모형


- X 값에 따라 모집단을 구획하여 각 구획별로 Y 값의 평균을 구한 것을 $E(Y|X)$ 라 표기할 때, $E(Y|X=x)$ 와 $E(Y|X=x+1)$ 의 차이를 α_1 이라 한다면, 이 α_1 은 X 값의 한 단위 변화에 따른 Y 의 평균의 차이.
- 만일 X 값에 따라 구분된 모든 구획에서 오차항의 평균이 0이면, 즉 만일 모든 X 값에서 $E(e|X)=0$ 이면 "인과적 영향"은 "평균의 차이"와 동일함
- "인과적 영향"은 직접 측정하기가 매우 어렵거나 거의 불가능한 반면, "평균의 차이"는 모집단의 분포(X 와 Y 두 변수의 결합확률분포)를 알기만 하면 알 수 있음
- 모든 X 값에서 $E(e|X)=0$ 이라고 가정하면, "평균의 차이"(대략적으로라도 측정 가능)를 "인과적 영향"(측정이 매우 어려움)으로 추론하여 해석할 수 있음 (주의)



1. 단순회귀모형

- $E(e|X)$ 가 X 값에 의존하지 않으면, 기울기(β_1)는 X 가 한 단위 증가할 때 Y 가 평균 얼마만큼 증가하는지를 나타냄
 - 예를 들어 X 가 교육연수이고 Y 가 임금이면, 교육연수가 1년 차이는 두 집단 간에는 평균 β_1 만큼의 임금 차이가 있음[$E(e|X)$ 가 X 값에 의존하지 않는 경우]
- $E(e|X)$ 가 X 값에 의존하지 않으면, 이 평균적 차이는 인과적 효과로 해석 가능

1. 단순회귀모형



1. 단순회귀모형

[모집단의 회귀방정식]

$$Y_i = \beta_1 + \beta_2 X_i + e_i, \quad i = 1, 2, \dots, n$$

[가정]

$E(e_i|x)=0$, by 4, X

① $E(e_i) = 0, \forall i$

by 1, $E(e_i)=0$

② $Var(e_i) = E(e_i^2) = \sigma^2, \forall i$

(homoscedasticity)

③ $Cov(e_i, e_j) = E(e_i e_j) = 0, \forall i \neq j$

④ X : non-stochastic

2. 고전적 가정

① $E(e_i) = 0, \forall i$

: 모든 사람들이 $Y_i = \beta_1 + \beta_2 X_i$ 와 같이 소비액이 결정되지는 않지만, 그보다 많이 쓰는 부분, 적게 쓰는 부분이 상쇄되어 평균적으로 0이 된다는 것

② $Var(e_i) = E(e_i^2) = \sigma^2, \forall i$

: X_i 가 얼마이든지 퍼진 정도가 같다는 것을 의미한다

(동분산 : homoscedasticity)

예를 들어, 소득 100만원인 사람들의 90%가 75 ± 25 만원을 소비한다고 하면, 소득 200만원인 사람들도 90%가 150 ± 25 를 소비한다는 것을 의미한다.

2. 고전적 가정

③ $Cov(e_i, e_j) = E(e_i e_j) = 0, \forall i \neq j$

: 서로 다른 잔차항 사이에는 아무런 관계가 없음을 의미한다. 이를 자기상관(no autocorrelation, no serial correlation)이 없다고 한다.

④ X : *non-stochastic*

: X 는 확률변수가 아님을 의미한다. 이 가정은 완화될 수 있으나, 분석의 편의상 X 는 반복해서 표본을 추출할 때 고정할 수 있다고 하자.

3. 표본회귀방정식

- 표본회귀방정식-> data, population X(sample regression equation)


$$: Y_i = \widehat{\beta}_1 + \widehat{\beta}_2 X_i + \widehat{e}_i$$

- β_1, β_2 는 우리가 알고 싶어하는 0이다.


- $\widehat{\beta}_1, \widehat{\beta}_2$ 은 표본의 함수로서 추정한 추정량(estimator)이다. 관찰값이 달라지면 $\widehat{\beta}_1, \widehat{\beta}_2$ 의 값도 달라지므로 이런 의미에서 $\widehat{\beta}_1, \widehat{\beta}_2$ 은 라고 할 수 있다.

* 직선 그리기

- 모수들(β_0 과 β_1)의 추정 = 자료의 산포도에 직선을 덧그리는 것과 동일함
 - 주: 인과관계를 염두에 두고 있으나, 추정한 것이 반드시 인과관계라는 법은 없음
- 예: 재정자립도 = $\beta_0 + \beta_1$ 공무원비율 + e
 - 모형에서는 암묵적으로 공무원비율이 원인, 재정자립도가 결과임을 의도함
 - 즉, 공무원비율이 재정자립도에 미치는 인과적 영향에 관심이 있음을 의미함
 - 그러나 (공무원비율, 재정자립도)의 관측치들의 그림에 직선을 덧그려도 이것이 반드시 인과관계를 의미해야 한다는 법은 없음




안 좋아 보임



더 나아 보임

1. 단순회귀모형과 해석

- 양의 실수에는 로그(log, 자연로그)를 취할 수 있음
- 이 로그 값은 컴퓨터로 계산할 수 있음
- 로그함수는 x에서의 접선의 기울기가 $1/x$ 임
- 이 함수는 숫자를 "지수적"으로 줄여 줌
- 접선의 기울기가 $1/x$ 이면서, 좁은 구간에서는 모양이 직선
가깝다는 성질을 이용하면 " $\log(x)$ 의 차이는 x의 증가율과
슷" 함을 보일 수 있음
- 즉, $\Delta \log(x)$ 가 작으면 $\Delta \log(x) \doteq (\Delta x)/x$



1. 단순회귀모형과 해석

- 예: $\log(\text{임금})$ 이 0.023 증가하면, 임금은 약 2.3% 증가 (0.023이 작음에 유의)
- 정확한 표현: 증가율 = $\exp(\text{로그값 증가분}) - 1$
 - 예: $\log(x)$ 가 0.9 증가하면 $\exp(0.9) - 1 = 1.46$ 이므로 x 는 146% 증가(0.9가 큼에 유의)
- 양(+)의 증가를 가질 때 정확한 증가율은 로그값 증가분보다 항상 더 큼
 - 예: $\log(x)$ 가 0.1 증가하면 x 의 증가율은 $\exp(0.1) - 1 = 0.105$, 즉 약 10.5% 증가
- 값이 감소할 때 정확한 감소율은 로그값 감소분보다 항상 더 작음
 - 예: $\log(x)$ 가 0.1 감소하면 x 의 증가율은 $\exp(-0.1) - 1 = -0.095$, 즉 약 9.5% 감소
- 로그값의 변화분은 증가할 때와 감소할 때의 변화율의 사이(정중앙은 아님)
- 로그값 변화분이 작으면(예: 0.1~0.2 이하), 로그값 변화분과 변화율이 유사하므로 $\exp(\text{로그값 증가분}) - 1$ 을 계산하기보다는 로그값 증가분을 변화율로 간주함

1. 단순회귀모형과 해석

- 수준-수준 모형: $Y = \beta_0 + \beta_1 X + e$ ($e=0$ 이면 X 의 한 단위 증가시 Y 는 β_1 단위 증가)
- 수준-로그 모형: $Y = \beta_0 + \beta_1 \log(X) + e$ (X 가 1% 증가하면 Y 는 약 $0.01 * \beta_1$ 단위 증가)
- 로그-수준 모형: $\log(Y) = \beta_0 + \beta_1 X + e$ (X 가 1 단위 증가하면 Y 는 약 $100 \beta_1 \%$ 증가)
- 로그-로그 모형: $\log(Y) = \beta_0 + \beta_1 \log(X) + e$ (X 가 1% 증가하면 Y 는 약 $\beta_1 \%$ 증가)
- " $\log(\text{수요량}) = \beta_0 - 0.5 * \log(\text{가격}) + e$ "라면 수요의 가격탄력성은 0.5 (혹은 -0.5)
- " $\log(\text{임금}) = \beta_0 + 0.06 * \text{학력} + e$ "에서 학력의 단위가 연이면 e 가 고정 될 때 학력이 1년 증가하면 임금은 약 6% 증가하는 것으로 추정됨
- 로그와 측정단위: 로그는 변화율처럼 측정단위를 변화시켜도 해석이 변하지 않으며, 따라서 로그를 취한 변수의 측정단위를 몰라도 해석에 지장이 없음. 절편만 영향을 받으나 절편에는 보통 별 관심이 없으므로 괜찮음

X 에 대한 Y 의 준탄력성(semi-elasticity)

1. 단순회귀모형과 해석


- 단위가 백분율이나 비율인 변수의 증가를 표현할 때에는 "1 퍼센트 포인트"처럼 "포인트"를 붙임
 - 예) 빈도가 0.5에서 0.6으로 증가하는 것은 0.1 포인트 증가
 - 예) 성장율이 3%에서 2.8%로 변하는 것은 0.2% 포인트 감소
- 그러므로 로그를 취하지 않은 변수에서는 단위 다음에 "포인트"를 붙인 다음, 뜻이 분명하여 "포인트"가 불필요하면 없애고 "단위"가 이상하면 없앴
 - 예) 연 단위로 측정한 학력이 1만큼 증가하는 것은 "1년 포인트 증가"인데 "포인트"가 없어도 뜻이 분명하므로 "1년 증가"라고 함
 - 예) 0~1 사이의 값으로 측정한 비율 변수의 증가는 "0.1 포인트 증가"와 같이 표현함
- 로그를 취한 변수의 증가는 100을 곱하여 "퍼센트 증가"라고 하는 것이 좋음

* 예제: 공무원 비율과 재정자립도

- $X = 2010\text{년 } \log(\text{공무원 비율}),$
 $Y = 2010\text{년 } \log(\text{재정자립도})$
- 84개 군(인천 옹진군, 경북 울릉군 제외) 자료를 사용하여 계산하면 $\hat{\beta}_1 = -0.8212, \hat{\beta}_0 = 4.767$
- 이 결과를 이용하여 자료의 그림에 직선을 덧그리면 우측과 같음

2010년 공무원수 비율이 10% 높은 군에서 재정자립도는 약 8.212% 낮은 것으로 예측됨


인과관계로 해석하지 말 것



* 예제: 소비함수

- $X =$ 가처분소득(1947I ~ 1996IV, "yd"),
 $Y =$ 개인소비지출("ce")
- 결과: $\hat{\beta}_1 = 0.8618$, $\hat{\beta}_0 = 6000.3$
- 이 결과를 이용하여 자료의 그림에 직선을 덧그리면 우측과 같음

가처분 소득이 100원 높은 기간의
개인소비지출은 86.18원 많은 것으로 추정됨



* 예제: 담배 가격과 판매량

- $X = \log(\text{price})$, $Y = \log(\text{sales})$
- 미국 46개 주의 1990년 담배 가격과 판매량 자료
- 결과: 절편 추정값은 9.0812, 기울기 추정값은 -0.8992
 - 가격이 1% 높은 주에서는 판매량이 약 0.9% 적었음(정확히 계산하면 약 0.82%)
 - 가격이 1% 낮은 주에서는 판매량이 약 0.9% 많았음(정확히 계산하면 약 0.99%)
- 판매량의 가격탄력성은 약 0.9 (또는 -0.9)

4. 최소제곱법

- 최소제곱법(OLS, ordinary least square)

: 점들로부터 직선까지의 거리의 제곱의 합을 가장 작게 하는 직선을 찾는 방법

$$\min \sum_{i=1}^n \hat{e}_i^2 = \sum_{i=1}^n (Y_i - \widehat{\beta}_1 - \widehat{\beta}_2 X_i)^2$$

4. 최소제곱법

$$\min \sum_{i=1}^n \hat{e}_i^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i)^2$$

- 1계조건(F.O.C)

①

②


- OLS 추정량

$$\hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{X} , \quad \hat{\beta}_2 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2}$$

4. 최소제곱법

- 회귀식 $Y_i = \widehat{\beta}_1 + \widehat{\beta}_2 X_i + \widehat{e}_i$ 을 deviation from mean으로 고쳐써보자

$$(Y_i - \bar{Y}) = \widehat{\beta}_2 (X_i - \bar{X}) + \widehat{e}_i$$



4. 최소제곱법

$$\widehat{\beta}_2 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) / (n-1)}{\sum (X_i - \bar{X})^2 / (n-1)}$$

=

4. 최소제곱법

note) 공분산과 상관계수

- 공분산: 확률변수 X 의 평균이 μ_X , Y 의 평균이 μ_Y 일 때,

X 와 Y 의 공분산(covariance)는 $\sigma_{XY} = Cov(X, Y) = E((X - \mu_X)(Y - \mu_Y))$

(그래프)

4. 최소제곱법


$$\text{Cov}(X, Y) = E((X - \mu_X)(Y - \mu_Y))$$

- 표분의 공분산
- 상관계수 : 확률변수 X 의 평균과 표준편차가 μ_X, σ_X , Y 의 평균과 표준편차가 μ_Y, σ_Y 일 때 X 와 Y 의 상관계수(correlation)는

$$\rho_{XY} = \text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

* 설명변수 표본값들이 모두 동일할 때


- $x_1 = x_2 = \dots = x_n$ 이면 $\hat{\beta}_1$ 식의 분모가 0이고 분자도 0
 - LS 추정값이 결정되지 않는 “특이한” 상황
- 이 “특이한” 상황에서는 직교방정식이 2개 있지만 하나가 쓸모 없는 여분의 것이 되어 유일한 추정값을 구할 수 없음(무수히 많은 추정값)
- “특이성”하에서는, 표본 내에서 x에 차이가 없음에도 불구하고 y의 개체간 차이를 x로써 설명하고자 하는 것이므로, 제대로 설명할 수 없는 것이 당연
- 해결책은 없음: 모형이나 데이터를 바꾸어 ‘특이성’이 생기지 않도록 할 것



$\bar{y}$ 를 지나기만 하면 어느 선이든 LS 추정식

* 맞춘값과 잔차

- 맞춘값(fitted values):
 $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i, i = 1, 2, \dots, n$
 - i 번째 개인에 대하여 모형이 맞춘 y 값
 - X 값이 x_i 와 같을 때 모형이 Y 의 값이라고 0 측하는 값(모형 "예측값")
 - X 값들의 1차함수로 만들어낼 수 있는 값 중 Y 표본값들에 가장 가까운 값
- 잔차(residuals): $\hat{u}_i = y_i - \hat{y}_i$
 - 개인 i 의 y 값 중 모형이 맞추지 못하고 남는 부분
 - $\hat{u}_i = y_i - \hat{y}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$



최소제곱의 기준에서
"가장 가까운"

- 맞춘값과 잔차의 성질

- 모든 i 에서 $y_i = \hat{y}_i + \hat{e}_i$ ($\hat{e}_i$ 를 그렇게 정의했으므로 당연함)
- 잔차들의 합은 0, 설명변수 값들과 잔차들의 곱의 합은 0
-

$$\sum_{i=1}^n \hat{e}_i = 0, \quad \sum_{i=1}^n x_i \hat{e}_i = 0$$

- 이 두 식은 최소제곱 추정을 위한 두 직교방정식($\hat{e}_i$ 기호를 사용하여 표현)
- 정확한 등식이며 근사적으로 0에 가깝다는 뜻이 아님(단, 컴퓨터 연산을 하면 정확히 0이 아니라 0에 가까운 값일 수 있는데, 이는 컴퓨터의 실수 저장과 연산이 불가피하게 부정확하기 때문임)
- 이 두 식이 만족되지 않으면 $\hat{e}_i$ 는 최소제곱으로부터의 잔차가 아님(뭔가 잘못된 것)
- 이를 이용하면 맞춘값과 잔차의 곱의 합($\sum_{i=1}^n \hat{y}_i \hat{e}_i$)이 0임을 보일 수 있음

최소제곱 추정의 기하학

